

Assignment 3 指南

*****注意，实验结束请立即删除云主机和集群，节省费用*****

*****注意2，实验未结束且短期内不会继续实验，也请删除云主机和集群。下次实验时重新创建*****

实验内容

- 安装Hadoop集群: 实验步骤 一)
- 了解并学习简单的Hadoop操作: 实验步骤 二)
- MapReduce Job 实验步骤 三)

实验要求（仔细看）

- 完成所有步骤，并在实验报告 ([模板下载](#))中完成穿插在本指南中的作业1 ~ 作业4（只需要截图）。实验报告上传至https://send2me.cn/bXq4_dxu/S4igi0IXyDOWZw
- 实验报告上传deadline: 10月13日23:59

使用产品

托管Hadoop集群UHadoop、云主机uhost、私有网络vpc、基础网络unet

需要权限

托管Hadoop集群UHadoop、云主机uhost、基础网络unet

基础知识

Hadoop: 一个分布式系统基础架构，由Apache基金会开发。用户可以在不了解分布式底层细节的情况下，开发分布式程序。充分利用集群的威力高速运算和存储。

Distributed: 分布式计算是利用互联网上的计算机的 CPU 的共同处理能力来解决大型计算问题的一种计算科学。

File system: 文件系统是操作系统用于明确磁盘或分区上的文件的方法和数据结构；即在磁盘上组织文件的方法。也指用于存储文件的磁盘或分区，或文件系统种类。

Hadoop 和 HDFS 的关系


- Hadoop实现了一个分布式文件系统（Hadoop Distributed File System），简称HDFS。
- 对外部客户机而言，HDFS 就像一个传统的分级文件系统。可以创建、删除、移动或重命名文件，等等。很多时候，我们就叫它DFS（Distributed File System）。
- Hadoop 是一个以一种可靠、高效、可伸缩的方式进行处理的，能够对大量数据进行分布式处理的系统框架。
- HDFS是Hadoop兼容最好的标准级文件系统，因为Hadoop是一个综合性的文件系统抽象，所以HDFS不是Hadoop必需的。所以可以理解为Hadoop是一个框架，HDFS是Hadoop中的一个部件。

实验步骤

一）安装Hadoop集群

进入产品页面

在“全部产品”菜单中点击“托管Hadoop集群 UHadoop” 进入产品页面。



创建集群



基本设置

地域

上海教育云

可用区

可用区C

所属VPC

DefaultVPC

创建新VPC请前往VPC页面

所属子网

DefaultNetwork(10.23.0.0/16)

创建新子网请前往子网页面

集群名称

hadoop

业务组

未分组

软件设置

集群框架

Hadoop框架

HDFS框架

计算框架

根据应用场景的不同，可选择不同的集群框架。
Hadoop框架适用于存储和计算在同一集群，HDFS框架和计算框架适用于存储计算分离架构。

发行版

uhadoop 2.2

框架版本

hadoop2.8.5-udh2.2

集群种类

Spark集群

Hbase集群

Core Hadoop集群

自定义

按照集群种类选择服务，可在一定程度上提高集群资源利用率，保证核心服务的可靠运行。

集群软件

Zookeeper 3.4.13 | Hive 2.3.6 | Hue 4.7.1 | Hdfs 2.8.5 | Yarn 2.8.5

来在此处选择的集群服务，在创建完集群后也可在控制台的软件管理中开启。

元数据独立管理

未开启

支付方式

按时

UHadoop集群

5.62 元

合计费用

5.62 元

立即购买

节点设置不需要改变，付费方式选择 按时 付费

根据集群规模不同，所需要的部署时间会有所差异，创建时间基本在 15 分钟 左右。初始，集群的转态是 创建/部署 中，需等到 状态变为 运行 才能操作集群

管理集群

在管理页面，我们可以查看集群中节点的信息、增加/关掉 节点、升级节点配置、查看监控信息和操作日志等

集群管理 / hadoop

集群管理

服务管理

Yarn Application跟踪

Yarn队列管理

节点管理

监控信息

操作日志

添加节点

自定义Hosts

升级Master节点

角色	节点	节点类型	IP	创建时间%	状态	操作
MASTER	uhadoop-in3wvki-master1 Web服务器规格(22, 3389, 80, 443)	C1-xlarge	(内)10.23.135.134	2020-10-12 15:30	运行	组件管理 登录 ...
MASTER	uhadoop-in3wvki-master2 Web服务器规格(22, 3389, 80, 443)	C1-xlarge	(内)10.23.93.165	2020-10-12 15:30	运行	组件管理 登录 ...
CORE1	uhadoop-in3wvki-core1	D2-large	(内)10.23.214.154	2020-10-12 15:30	运行	组件管理 登录 ...
CORE	uhadoop-in3wvki-core2	D2-large	(内)10.23.32.248	2020-10-12 15:30	运行	组件管理 登录 ...
CORE	uhadoop-in3wvki-core3	D2-large	(内)10.23.84.89	2020-10-12 15:30	运行	组件管理 登录 ...

1


10 条/页

连接集群

连接集群可通过绑定EIP、搭建客户端两种方式实现，由于目前ucloud平台的EIP服务存在bug，在此实现由客户端连接集群

先创建一台云主机（请修改默认配置，选择CentOS7操作系统！！）

安装客户端



按照创建云主机时的root账号和密码进行输入

安装客户端

安装集群: hadoop | uhadoop-gehussikht6

选择主机 *

uhost-gerl64ahq96 (10.9.150.130)

主机信息

登录名 *

root

登录密码 *

请输入登录密码

登录端口 *

请输入登录端口

取消

确定

本地通过ssh连接登录云主机，即登录了集群

```
ssh root@106.75.249.169
```

查看HDFS状态，节点信息

```
hdfs dfsadmin -report 查看信息
```

*****作业1：请将上述查看到的节点信息截图，并插入实验报告中*****

二) 熟悉基本命令

Hadoop实现了一个分布式文件系统（Hadoop Distributed File System），简称HDFS。我们可以登录Master节点通过一些基本命令操作文件，操作的命令与我们在Linux系统命令类似。所有的操作都在root用户下执行，避免出现权限问题

列出文件

```
hadoop fs -ls  
eg : hadoop fs -ls /
```

创建目录

hadoop fs -mkdir 接受路径指定的uri作为参数，创建这些目录。其行为类似于Unix的mkdir -p，它会创建路径中的各级父目录。
eg: hadoop fs -mkdir /dir1 /dir2 （该目录时被创建在HDFS文件系统中，而不是本地文件系统）

上传文件

hadoop fs -put 从本地文件系统中上传文件到HDFS文件系统中
eg: hadoop fs -put /root/install-java.sh /dir1 本地文件： /root/install-java.sh
HDFS文件系统中文件夹： /dir1

下载文件

hadoop fs -get 从HDFS文件系统中下载文件到本地
mkdir test && hadoop fs -get /dir1/install-java.sh /root/test

检查文件

使用方法：hadoop fs -test [-ezd] url
选项：
-e 检查文件是否存在。如果存在则返回0。
-z 检查文件是否是0字节。如果是则返回0。
-d 如果路径是个目录，则返回1，否则返回0。
示例：
• hadoop fs -test -e filename

更多请参考： **hadoop fs -help** 也可以参考：[Hadoop FS Shell使用指南](#)

*****作业2：按照如下要求操作命令并根据3和4的要求截图，并插入实验报告中*****

作业二要求：

1. 在本地文件系统生成一个info.txt文件 里面内容是： 云计算实验课:学号-姓名 eg: echo "云计算实验课:0001-张三" > info.txt
2. 在HDFS文件系统中创建文件夹 test, 然后将该文件上传到该文件夹中 使用 `mkdir` 和 `put`
3. 使用cat命令查看文件内容并截图 截图中需要包含文件夹信息 （查看的是HDFS文件系统上的info.txt, 而不是本地文件系统）
4. 删除info.txt和test文件夹并截图

操作时注意使用的用户和目录，避免出现permission denied问题

三) MapReduce Job

MapReduce是一种分布式计算框架，以一种可靠的，具有容错能力的方式并行地处理上TB级别的海量数据集。MR有两个阶段组成：Map和Reduce，用户只需实现map()和reduce()两个函数，即可实现分布式计算。在/root/hadoop-2.6.0/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.8.5.jar 中有很多简单的MapReduce实例程序。我们可以通过在master节点执行命令 `hadoop jar /root/hadoop-2.6.0/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.8.5.jar` 可以看到可以运行的实例程序。

```
[root@10-9-158-18 ~]# cd /root/hadoop-2.6.0/share/hadoop/mapreduce
[root@10-9-158-18 mapreduce]# ls
hadoop-mapreduce-client-app-2.8.5.jar      hadoop-mapreduce-client-hs-2.8.5.jar      hadoop-mapreduce-client-jobclient-2.8.5-tests.jar  jdiff      sources
hadoop-mapreduce-client-common-2.8.5.jar   hadoop-mapreduce-client-hs-plugins-2.8.5.jar  hadoop-mapreduce-client-shuffle-2.8.5.jar          lib
hadoop-mapreduce-client-core-2.8.5.jar     hadoop-mapreduce-client-jobclient-2.8.5.jar  hadoop-mapreduce-examples-2.8.5.jar                lib-examples
[root@10-9-158-18 mapreduce]# hadoop jar hadoop-mapreduce-examples-2.8.5.jar
An example program must be given as the first argument.
Valid program names are:
aggregatewordcount: An Aggregate based map/reduce program that counts the words in the input files.
aggregatewordhist: An Aggregate based map/reduce program that computes the histogram of the words in the input files.
bbp: A map/reduce program that uses Bailey-Borwein-Plouffe to compute exact digits of Pi.
dbcount: An example job that count the pageview counts from a database.
distbbp: A map/reduce program that uses a BBP-type formula to compute exact bits of Pi.
grep: A map/reduce program that counts the matches of a regex in the input.
join: A job that effects a join over sorted, equally partitioned datasets
multifilewc: A job that counts words from several files.
pentomino: A map/reduce tile laying program to find solutions to pentomino problems.
pi: A map/reduce program that estimates Pi using a quasi-Monte Carlo method.
randomtextwriter: A map/reduce program that writes 10GB of random textual data per node.
randomwriter: A map/reduce program that writes 10GB of random data per node.
secondarysort: An example defining a secondary sort to the reduce.
sort: A map/reduce program that sorts the data written by the random writer.
sudoku: A sudoku solver.
teragen: Generate data for the terasort
terasort: Run the terasort
terasortvalidate: Checking results of terasort
wordcount: A map/reduce program that counts the words in the input files.
wordmean: A map/reduce program that counts the average length of the words in the input files.
wordmedian: A map/reduce program that counts the median length of the words in the input files.
wordstandarddeviation: A map/reduce program that counts the standard deviation of the length of the words in the input files.
```

统计词频

- 创建目录，并上传测试数据（所有操作在集群的master节点执行）

```
hadoop fs -mkdir /input
hadoop fs -put /root/hadoop-2.6.0/conf/* /input
```

- 执行WordCount任务

```
hadoop jar /root/hadoop-2.6.0/share/hadoop/mapreduce/hadoop-mapreduce-examples-2.8.5.jar
wordcount /input /output  如果/output目录已存在，请删除该目录或使用其他目录。
```

- 查看wordcount任务的结果


```
hadoop fs -cat /output/part-r-00000
```

*****作业3：统计/root/hadoop-2.6.0/etc/hadoop目录下所有文件的词频并截图，插入实验报告中*****

*****特别注意，做完作业3 即可请删除UHadoop集群、EIP和UHost主机等资源*****

WordCount 实现原理

MapReduce主要分为两步Map步和Reduce步，引用网上流传很广的一个故事来解释，现在你要统计一个图书馆里面有多少本书，为了完成这个任务，你可以指派小明去统计书架1，指派小红去统计书架2，这个指派的过程就是Map步，最后，每个人统计完属于自己负责的书架后，再对每个人的结果进行累加统计，这个过程就是Reduce步。下图是WordCount的实现原理图，[WordCount实现](#)。



*****作业4：用任一语言实现单线程的wordCount，记录运行时间，然后给出运行时间截图，插入实验报告中*****

作业要求

需要统计的文件夹：[/hadoop](#)

在本地执行，并记录执行时间