

Assignment 5 指南

*****注意，实验结束请立即删除云主机和数据仓库，节省费用*****

*****注意2，实验未结束且短期内不会继续实验，也请删除云主机和数据仓库。下次实验时重新创建*****

实验内容

- 创建Clickhouse数据仓库实例: [实验步骤 一](#))
- 登录数据仓库，并练习建表、插入、查找等基本操作: [实验步骤 二](#))
- 使用clickhouse完成简单的机器学习任务: [实验步骤 三](#))

实验要求（仔细看）

- 完成所有步骤，并在实验报告 ([模板下载](#))中完成穿插在本指南中的作业1 ~ 作业4（只需要截图）。实验报告上传至: <https://send2me.cn/ynNfA6Q0/RFC4OpEdpgJcNg>
- 实验报告上传deadline: [10月27日23:59](#)

使用UCloud产品

云数据仓库UDW、云主机uhost、私有网络vpc、基础网络unet

需要权限


云数据仓库UDW、云主机uhost、基础网络unet

基础知识（本实验详细知识会在数据仓库相关课程中学习，这里我们仅简单熟悉一下相关操作，你也可以去Google上Baidu一下相关知识 🐼 🐼 🐼）

数据仓库： data warehouse（缩写DW），是用于报告和数据分析的数据管理系统。

和SQL数据库的区别： 传统的关系型数据库（如实验四中的MySQL）主要应用于基本的、日常的事务处理（Transaction Processing），例如银行交易，淘宝购物，订购车票等。而数据仓库系统主要应用于生产数据的整理和分析（Analytical Processing），通过扩展数据分析和可视化等工具，支持业务决策，例如流量分析、用户画像、统计建模等。

举个简单例子，淘宝前端（网页端、app端）每天的交易事务，都是用关系型数据库支持的。而每天的交易数据，会定时导入到后端的数据仓库（俗称ETL，Extract, Transform, Load），并根据特定业务逻辑重新整理，从而方便后端各个团队分析数据和做出业务决策。



Clickhouse数据仓库：是由俄罗斯公司Yandex开发的一种列式数据库管理系统，也可以用作数据仓库。它以高性能、高并发和高可扩展性而闻名，能够处理PB级别的数据集，并支持实时查询和分析。

与传统的关系型数据库管理系统（如MySQL和PostgreSQL）不同，Clickhouse采用列式存储方式，将每个列单独存储在硬盘上，而不是按行存储。这种存储方式使得Clickhouse在数据压缩、查询性能、批量插入等方面具有优势，适用于大数据量的实时查询和分析场景。

Clickhouse支持多种查询语言，包括SQL、HiveQL和ODBC等，并且可以与各种数据源集成，如Hadoop、Kafka、Elasticsearch等。同时，Clickhouse还具有高度的可扩展性，可以通过添加节点来实现水平扩展，以满足不断增长的数据处理需求。

ClickHouse也内置了许多机器学习算法，例如基于梯度下降的线性回归、逻辑回归、SVM、决策树、随机森林、PCA等。这些算法都是使用ClickHouse的SQL语言编写的，并且可以通过简单的SQL查询进行调用和使用。除了内置的算法，ClickHouse还提供了一些用于机器学习的函数和工具，例如数组函数、向量函数、一些聚合函数等。这些函数可以用于数据清洗、特征工程、数据转换等任务。

闲话少说，我们开始创建一个Clickhouse数据仓库玩玩。🐼🐼🐼

实验步骤

一）创建Clickhouse数据仓库实例

1) 在产品中选择云数据仓库UDW Clickhouse，然后点击创建集群

数据仓库

数据仓库 UDW Greenplum

数据仓库 UDW Clickhouse

数据仓库 UDW Apache Doris

2) 配置中, 选择版本22.3LTS, 云盘容量选择200G, 节点个数选择2个节点。子网设成"DefaultNetwork", 记住DB名称, 端口, 管理员用户名, 设置管理员密码。选择按时付费, 立即购买。

地域

地域可用区

华北一

可用区8

配置选择

版本

22.8 LTS

22.3 LTS

21.8 LTS

21.3 LTS

计算规格

标准型

s1

计算型

c1

CPU/内存

s1-x1

CPU

4C

内存

16G

s1-x2

CPU

8C

内存

32G

s1-x4

CPU

16C

内存

64G

s1-x8

CPU

32C

内存

128G

s1-x16

CPU

64C

内存

256G

云盘类型

RSSD 型云盘

200

说明: Clickhouse的存储特性对磁盘吞吐量要求很高, 为保证Clickhouse的性能优势, 因此仅提供RSSD云盘。

云盘容量

8000

16000

24000

32000

200 G

副本

双副本

单副本

副本说明:

双副本模式具备高可用特性, 每2个副本节点组成一个分片, 分片内节点不可用时另一个节点可以继续提供服务能力 (需要结合副本表引擎使用)

单副本模式不承诺SLA, 建议仅在测试/开发环境使用, 生产环境推荐使用双副本模式。

节点个数

2

4

节点说明: 双副本模式支持2节点、4节点。单副本模式仅支持1节点。

网络设置

所属VPC

DefaultVPC ▾ ↻

所属子网

DefaultNetwork(10.9.0.0/16) ▾ ↻

DB设置

数据仓库名称

clickhouse

DB服务端口

9000

DB管理员用户名

admin

· 密码长度限8-30个字符

· 不能包含[A-Z],[a-z],[0-9]之外的非法字符

· 需同时包含大小写字母和数字

密码 *

Linlinshe1

⦿

购买数量

-

1

+

集群配额

1/98 

☒ 按时

1.83 元

折合: 1317.6元 / 月

☐ 月付

133.33 元

购至月末 

月单价: 907.2元 / 月

☐ 年付

9072 元

1年 

折合: 756元 / 月

合计费用

1.83 元

立即购买

3) 支付之后, 数仓创建时间从几分钟到十几分钟不等, 等状态显示“运行中”, 则创建完毕。

创建集群

集群名称 	资源ID	节点个数 	副本数 	版本	创建时间 	状态 	操作
clickhouse 修改名称	uck-gylg51qbxgo	2	2	22.3.6.5	2023-03-25 14:48:27	 运行中	详情 配置升降级 

二) 登录数据仓库。Clickhouse数据仓库的登录有很多方式，比如用clickhouse客户端登录，用JDBC（在Java中使用）或者ODBC（在C/C++中使用）访问，用clickhouse-driver（在Python中使用）访问。本实验我们完成clickhouse客户端和clickhouse-driver两种方式。其余方式同学们以后可以自行尝试。

1) 使用Clickhouse客户端登录。创建一个最低配置的Centos云主机，选择按流量计费，20M带宽，云主机按小时付费。登录云主机以后运行以下命令，下载Clickhouse安装包。

```
wget https://packages.clickhouse.com/rpm/lts/clickhouse-client-22.3.6.5.noarch.rpm
wget https://packages.clickhouse.com/rpm/lts/clickhouse-common-static-22.3.6.5.x86_64.rpm
```

安装

```
rpm -ivh clickhouse-common-static-22.3.6.5.x86_64.rpm
rpm -ivh clickhouse-client-22.3.6.5.noarch.rpm
```

1.1) 安装完毕后运行以下命令登录数据仓库。将相关参数替换成你的数据仓库参数。

```
clickhouse-client --host=<下图任一节点IP地址> --port=9000 --user=admin --password=<创建集群时设置的密码>
```

The screenshot displays the ClickHouse management interface. On the left, there are tabs for 'Overview', 'Monitoring Information', 'Configuration Management', 'Cluster Inspection', and 'Operation Log'. The 'Overview' tab is active, showing 'Basic Information' and 'Configuration Information'. The 'Basic Information' section includes fields for 'Resource Name' (clickhouse), 'Resource ID' (uck-gylg51qlxgo), and 'Status' (Running). The 'Configuration Information' section lists 'Internal Version' (22.3.6.5), 'Calculation Specification' (Calculation Type), 'CPU (Cores)' (8), 'Memory' (16GB), 'Disk Type' (RSSD Type Cloud Disk), and 'Disk' (200GB). The 'Cluster Inspection' section shows a table of nodes with columns for 'Shard ID', 'Node ID', 'IP Address', 'Status', and 'Operations'. Two nodes are listed, both with 'Running' status. The IP addresses 10.9.48.54 and 10.9.186.201 are highlighted with red boxes.

分片ID	节点ID	IP地址	状态	操作
0	uck-gylg51qlxgo-ck-0-0	10.9.48.54	运行中	启动 重启
0	uck-gylg51qlxgo-ck-0-1	10.9.186.201	运行中	启动 重启

登录后将看到如下界面

```
[root@10-9-130-147 ~]# clickhouse-client --host=10.9.100.182 --port=9000 --user=admin --password=Linlinshe1
ClickHouse client version 22.3.6.5 (official build).
Connecting to 10.9.100.182:9000 as user admin.
Connected to ClickHouse server version 22.3.6 revision 54455.

uck-h175axmsqs8-ck-0-0 :) █
```

*****作业1：请将登录命令和登录成功界面截图，并插入实验报告*****

1.2) 让我们运行几个SQL代码来实现建表，插入，查询等操作。

创建数据库 `ck_test`

```
CREATE DATABASE IF NOT EXISTS ck_test ON CLUSTER ck_cluster;
```

注： `on cluster ck_cluster` 表示在双副本模式下建库/建表

创建表 `regression`

```
CREATE TABLE ck_test.regression ON CLUSTER ck_cluster
(
    id Int32,
    y Int32,
    x1 Int32,
    x2 Int32
)
ENGINE = ReplicatedMergeTree(
    '/clickhouse/ck_test/tables/{layer}-{shard}/regression',
    '{replica}'
) ORDER BY (id);
```

ClickHouse支持各种数据类型，包括基本数据类型、日期时间类型、文本类型、枚举类型等，还支持自定义数据类型，以满足特定的需求。

接着让我们在`regression`表中插入一些值

```
INSERT INTO ck_test.regression VALUES
(1, 5, 2, 3),
(2, 10, 7, 2),
(3, 6, 4, 1),
(4, 8, 3, 4);
```

让我们查询一下`regression`表中的数据。你应该看到如下输出。

```
SELECT * FROM ck_test.regression;
```

```

uck-h175axmsqs8-ck-0-0 :) SELECT * FROM ck_test.regression;

SELECT *
FROM ck_test.regression

Query id: 9f7e33c8-92a9-4ace-a10b-f2ef0c4b96e4



| id | y  | x1 | x2 |
|----|----|----|----|
| 1  | 5  | 2  | 3  |
| 2  | 10 | 7  | 2  |
| 3  | 6  | 4  | 1  |
| 4  | 8  | 3  | 4  |



4 rows in set. Elapsed: 0.004 sec.

uck-h175axmsqs8-ck-0-0 :)

```

1.3) 运行\q退出clickhouse客户端。

*****作业2：请如上图一样将regression表的查询命令、输出结果和退出clickhouse以后的界面截图，并插入实验报告*****

2) 使用 Python+clickhouse-driver 模块访问。很多时候我们需要在程序中访问数据仓库，比如用Python读取DW中的数据，然后进一步操作。clickhouse-driver是一个开源的Python模块，它提供了一个Python DB API 2.0兼容的接口，可以通过Python程序连接和操作ClickHouse数据库。

运行以下命令安装python环境

```

sudo yum install python3
sudo yum install python3-pip

```

安装clickhouse-driver

```

pip3 install clickhouse-driver

```

2.1) 安装完毕后运行python3，然后import clickhouse_driver，若没有报错，则说明clickhouse_driver安装成功。

```

[root@10-9-130-147 ~]# python3
Python 3.6.8 (default, Aug 24 2020, 17:57:11)
[GCC 8.3.1 20191121 (Red Hat 8.3.1-5)] on linux
Type "help", "copyright", "credits" or "license" for more information.
>>> import clickhouse_driver
>>>

```


2.2) quit()退出python3命令行，让我们运行几个Python代码来实现建表，插入，查询等操作。

建立createTable.py文件（若忘记创建文件命令可参考[实验一](#)），并复制如下代码。其中username, password, hostIP, port都要替换成你的数据仓库参数。

```
import clickhouse_driver

# 建立连接
conn = clickhouse_driver.connect(database="ck_test", user="admin", password="Linlinshe1",
host="10.9.100.182", port="9000")

# 创建游标
cur = conn.cursor()

# 创建表
cur.execute('CREATE TABLE COMPANY ON CLUSTER ck_cluster \
                                                    (ID Int32 NOT NULL,\
                                                    NAME String NOT NULL,\
                                                    AGE Int16 NOT NULL,\
                                                    ADDRESS String,\
                                                    SALARY Float64, \
                                                    PRIMARY KEY (ID)) \
                                                    ENGINE = MergeTree() \
                                                    ORDER BY (ID);')

# 提交事务
conn.commit()

# 关闭连接
conn.close()
```

运行createTable.py，如果没有报错，则说明建表成功。

```
python3 createTable.py
```

向COMPANY表中添加一些记录。建立insertTable.py文件，复制如下代码并运行。

```
import clickhouse_driver

# 建立连接
conn = clickhouse_driver.connect(database="ck_test", user="admin", password="Linlinshe1",
host="10.9.100.182", port="9000")


cur = conn.cursor()
cur.execute("INSERT INTO COMPANY VALUES (1, 'Paul', 32, 'California', 20000.00 );");
cur.execute("INSERT INTO COMPANY VALUES (2, 'Allen', 25, 'Texas', 15000.00 );");
cur.execute("INSERT INTO COMPANY VALUES (3, 'Eric', 35, 'Florida', 25000.00 );");
conn.commit()
conn.close()
```

让我们查询一下刚刚建的表。建立selectTable.py文件，复制如下代码并运行。

```
import clickhouse_driver

# 建立连接
conn = clickhouse_driver.connect(database="ck_test", user="admin", password="Linlinshe1",
host="10.9.100.182", port="9000")
cur = conn.cursor()
cur.execute("SELECT ID, NAME, ADDRESS, SALARY from COMPANY order by ID")
rows = cur.fetchall()
print ("ID      NAME      ADDRESS      SALARY")
for row in rows:
    print (row[0], "\t", row[1], "\t", row[2], "\t", row[3])
conn.close()
```

你应该会看到如下输出。



```
[root@10-9-130-147 ~]# python3 selectTable.py
ID      NAME      ADDRESS      SALARY
1       Paul      California    20000.0
2       Allen     Texas        15000.0
3       Eric      Florida      25000.0
```

以上只是一个简单的示例，clickhouse-driver还提供了更多的功能和选项，如使用参数化查询、执行多个查询、事务处理等。你可以在官方文档中了解更多信息：<https://clickhouse-driver.readthedocs.io/en/latest/index.html>。

*****作业3：请将运行selectTable.py的命令和输出结果截图，并插入实验报告*****

三) 使用clickhouse完成简单的机器学习任务（线性回归）

1) 前面我们说过，Clickhouse也可用于搭建机器学习模型。这里我们用二) 中的regression表跑一下线性回归算法。请使用clickhouse或者clickhouse-driver登录数仓后，并运行如下命令。

1.1) 确认训练数据

```
select * from ck_test.regression
```

```
[root@10-9-130-147 ~]# clickhouse-client --host=10.9.100.182 --port=9000 --user=admin --password=Linlinshe1;
ClickHouse client version 22.3.6.5 (official build).
Connecting to 10.9.100.182:9000 as user admin.
Connected to ClickHouse server version 22.3.6 revision 54455.

uck-h175axmsqs8-ck-0-0 :) select * from ck_test.regression

SELECT *
FROM ck_test.regression

Query id: 1f1558ca-6870-4519-8fa6-0467557f5acd
```

id	y	x1	x2
1	5	2	3
2	10	7	2
3	6	4	1
4	8	3	4

```
4 rows in set. Elapsed: 0.010 sec.

uck-h175axmsqs8-ck-0-0 :) █
```

这里我们看到数据量很少，因此 `regression` 同时是训练集和测试集。

使用了MADlib的线性回归模型 `linreg_train` 来对 `regression` 表中的数据进行训练，模型输入变量为 `x1`, `x2` 以及偏置项，输出变量为 `y`。训练好的模型保存在 `regression_model` 表中。

2) 训练线性回归模型，并将模型参数存入 `linear_model` 表中。

```
CREATE TABLE linear_model ENGINE = Memory AS SELECT stochasticLinearRegressionState(0.01, 0.1, 2, 'SGD')(y, x1, x2) AS state FROM ck_test.regression;
```

模型输出变量为 `y`, 输入变量为 `x1`, `x2`。 `stochasticLinearRegressionState` 的四个参数分别为：

1. learning rate
2. l2 regularization coefficient
3. mini-batch size
4. method for updating weights

如果要查看训练好的模型参数，则使用以下方式训练模型

```
SELECT stochasticLinearRegression(0.01, 0.1, 2)(y, x1, x2) FROM ck_test.regression;
```

```
uck-h175axmsqs8-ck-0-0 :) SELECT stochasticLinearRegression(0.01, 0.1, 2)(y, x1, x2) FROM ck_test.regression;

SELECT stochasticLinearRegression(0.01, 0.1, 2)(y, x1, x2)
FROM ck_test.regression

Query id: 97eaf8b8-e3ca-4816-a82d-3c720fd7400e
```

<code>stochasticLinearRegression(0.01, 0.1, 2)(y, x1, x2)</code>
<code>[0.019561782943289238,0.020012289061927653,0.019971629018659252]</code>

```
1 rows in set. Elapsed: 0.005 sec.

uck-h175axmsqs8-ck-0-0 :) █
```

3) 最后让我们用这个模型去做预测（前提是已将模型参数保存在表中）。我们直接在训练集上进行预测。

```
WITH (SELECT state FROM linear_model) AS model SELECT evalMLMethod(model, x1, x2) FROM ck_test.regression
```

你会看到如下输出，即模型对四组输入的预测结果

```
uck-h175axmsqs8-ck-0-0 :) WITH (SELECT state FROM linear_model) AS model SELECT evalMLMethod(model, x1, x2) FROM ck_test.regression

WITH (
  SELECT state
  FROM linear_model
) AS model
SELECT evalMLMethod(model, x1, x2)
FROM ck_test.regression

Query id: 6688b733-6833-416c-a757-ee92546e4d69

+evalMLMethod(model, x1, x2)+
+-----+
+3.8402+
+8.365400000000001+
+4.7954+
+5.3864+
+-----+

4 rows in set. Elapsed: 0.005 sec.
```

4) 运行\q退出clickhouse客户端。

*****作业4：请如上图一样把模型参数和预测结果的界面一起截图，并插入实验报告*****