

## 《数据科学与工程数学基础》第9次作业答案

1. 设  $\exp(z_i)$  表示  $\exp(z)$  的第  $i$  个分量,  $\log(q_i)$  表示  $\log(q)$  的第  $i$  个分量.  $f(z) = \frac{\exp(z)}{\mathbf{1}^T \exp(z)}$  称为 softmax 函数. 若  $q = f(z)$ ,  $J = -\mathbf{p}^T \log(q)$  (其中  $\mathbf{p}, \mathbf{q}, z \in \mathbb{R}^n$ , 且  $\mathbf{1}^T \mathbf{p} = 1$ ) :

(1) 证明:  $\frac{\partial J}{\partial z} = \mathbf{q} - \mathbf{p}$

(2) 若  $z = Wx$  (其中  $W \in \mathbb{R}^{n \times m}$ ,  $x \in \mathbb{R}^m$ ) , 判断  $\frac{\partial J}{\partial W} = (\mathbf{q} - \mathbf{p})x^T$  是否成立.

解:

(1) 首先推导  $J$  的表达式并求  $\frac{\partial J}{\partial z}$  :

$$\begin{aligned} J &= -\mathbf{p}^T \log \left( \frac{\exp(z)}{\mathbf{1}^T \exp(z)} \right) \\ &= -\mathbf{p}^T z + \mathbf{p}^T \log (\mathbf{1}^T \exp(z)) \mathbf{1} \\ &= -\mathbf{p}^T z + \mathbf{p}^T \log (\mathbf{1}^T \exp(z)) \\ &= -\mathbf{p}^T z + \log (\mathbf{1}^T \exp(z)) \end{aligned}$$

对  $z$  求偏导:

$$\begin{aligned} \frac{\partial J}{\partial z} &= -\mathbf{p} + \frac{\partial \log (\mathbf{1}^T \exp(z))}{\partial z} \\ &= -\mathbf{p} + \frac{\frac{\partial \mathbf{1}^T \exp(z)}{\partial z}}{\mathbf{1}^T \exp(z)} \\ &= -\mathbf{p} + \frac{\exp(z)}{\mathbf{1}^T \exp(z)} \\ &= -\mathbf{p} + \mathbf{q} \end{aligned}$$

(2) 分析  $\frac{\partial J}{\partial W}$  :

$$dJ = d\text{Tr}(J) = \text{Tr}(dJ) = \text{Tr}[(\mathbf{q} - \mathbf{p})^T dWx] = \text{Tr}[x(\mathbf{q} - \mathbf{p})^T dW]$$

因此:

$$\frac{\partial J}{\partial W} = (\mathbf{q} - \mathbf{p})x^T$$

2. 以下内容是利用极大似然估计求解多元正态分布模型的关键步骤:

$$L = -\frac{Nd}{2} \ln(2\pi) - \frac{N}{2} \ln |\Sigma| - \frac{1}{2} \sum_t (x_t - \mu)^T \Sigma^{-1} (x_t - \mu)$$

其中,  $L$  是对数似然,  $N$  为样本数,  $d$  为样本维数,  $\Sigma \in \mathbb{R}^{d \times d}$  为协方差矩阵,  $\mu \in \mathbb{R}^d$  为期望向量.

(1) 求  $\frac{\partial L}{\partial \mu}$

(2) 当  $\mu = \frac{1}{N} \sum_t x_t$  时, 求  $\frac{\partial L}{\partial \Sigma}$ , 并求使  $\frac{\partial L}{\partial \Sigma} = 0$  成立的  $\Sigma$ .

解:

(1)

$$\frac{\partial L}{\partial \mu} = \sum_t \Sigma^{-1} (x_t - \mu)$$

(2)

$$dL = d \left[ \frac{N}{2} \ln |\Sigma| \right] - d \left[ \frac{1}{2} \sum_t (x_t - \mu)^T \Sigma^{-1} (x_t - \mu) \right]$$

第一项为:

$$d \left[ \frac{N}{2} \ln |\Sigma| \right] = -\frac{N}{2} d(\ln |\Sigma|) = -\frac{N}{2} \text{Tr}[\Sigma^{-1} d\Sigma]$$

第二项为：

$$\begin{aligned}
 d\left[\frac{1}{2}\sum_t(x_t-\mu)^T\Sigma^{-1}(x_t-\mu)\right] &= -\frac{1}{2}d\text{Tr}\left[\sum_t(x_t-\mu)^T\Sigma^{-1}(x_t-\mu)\right] \\
 &= -\frac{1}{2}d\text{Tr}\left[\sum_t(x_t-\mu)(x_t-\mu)^T\Sigma^{-1}\right] \\
 &= -\frac{1}{2}\text{Tr}\left[\sum_t(x_t-\mu)(x_t-\mu)^T(-\Sigma^{-1}(d\Sigma)\Sigma^{-1})\right] \\
 &= \frac{1}{2}\text{Tr}\left[\Sigma^{-1}\sum_t(x_t-\mu)(x_t-\mu)^T\Sigma^{-1}d\Sigma\right]
 \end{aligned}$$

得到：

$$\frac{\partial L}{\partial \Sigma} = -\frac{N}{2}\Sigma^{-1} + \frac{1}{2}\Sigma^{-1}\sum_t(x_t-\mu)(x_t-\mu)^T\Sigma^{-1}$$

令  $\frac{\partial L}{\partial \Sigma} = 0$ ，易得

$$\Sigma = \frac{1}{N}\sum_t(x_t-\mu)(x_t-\mu)^T$$

3. 求  $\frac{\partial |\mathbf{X}^k|}{\partial \mathbf{X}}$ ，其中  $\mathbf{X} \in \mathbb{R}^{m \times m}$  为可逆矩阵。

解：

$$\frac{\partial |\mathbf{X}^k|}{\partial \mathbf{X}} = \frac{\partial |\mathbf{X}^k|}{\partial |\mathbf{X}|} \cdot \frac{\partial |\mathbf{X}|}{\partial \mathbf{X}} = k|\mathbf{X}|^{k-1} \cdot |\mathbf{X}|\mathbf{X}^{-T} = k|\mathbf{X}|^k \mathbf{X}^{-T}$$

4. 求  $\frac{\partial \text{Tr}(\mathbf{A}\mathbf{X}\mathbf{B}\mathbf{X}^T\mathbf{C})}{\partial \mathbf{X}}$ ，其中  $\mathbf{A} \in \mathbb{R}^{m \times n}$ ,  $\mathbf{X} \in \mathbb{R}^{n \times k}$ ,  $\mathbf{B} \in \mathbb{R}^{k \times k}$ ,  $\mathbf{C} \in \mathbb{R}^{n \times m}$ 。

解：

$$\begin{aligned}
 d(\text{Tr}(\mathbf{A}\mathbf{X}\mathbf{B}\mathbf{X}^T\mathbf{C})) &= \text{Tr}[d(\mathbf{A}\mathbf{X}\mathbf{B}\mathbf{X}^T\mathbf{C})] \\
 &= \text{Tr}[Ad(\mathbf{X}\mathbf{B}\mathbf{X}^T\mathbf{C}) + d\mathbf{A} \cdot (\mathbf{X}\mathbf{B}\mathbf{X}^T\mathbf{C})] \\
 &= \text{Tr}[\mathbf{A}\mathbf{X}d(\mathbf{B}\mathbf{X}^T\mathbf{C}) + \mathbf{A}d\mathbf{X} \cdot (\mathbf{B}\mathbf{X}^T\mathbf{C}) + \text{其它与 } d\mathbf{X} \text{ 无关的项}] \\
 &= \text{Tr}[\mathbf{A}\mathbf{X}\mathbf{B}d(\mathbf{X}^T\mathbf{C}) + \mathbf{A}\mathbf{X}d\mathbf{B} \cdot (\mathbf{X}^T\mathbf{C}) + \mathbf{B}\mathbf{X}^T\mathbf{C}d\mathbf{A}\mathbf{X} + \text{其它与 } d\mathbf{X} \text{ 无关的项}] \\
 &= \text{Tr}[\mathbf{A}\mathbf{X}\mathbf{B}\mathbf{X}^Td\mathbf{C} + \mathbf{A}\mathbf{X}\mathbf{B}d\mathbf{X}^T \cdot \mathbf{C} + \mathbf{B}\mathbf{X}^T\mathbf{C}d\mathbf{A}\mathbf{X} + \text{其它与 } d\mathbf{X} \text{ 无关的项}] \\
 &= \text{Tr}[(d\mathbf{X})^T[(\mathbf{C}\mathbf{A}\mathbf{X}\mathbf{B})^T]^T + \mathbf{B}\mathbf{X}^T\mathbf{C}d\mathbf{A}\mathbf{X} + \text{其它与 } d\mathbf{X} \text{ 无关的项}] \\
 &= \text{Tr}\{[(\mathbf{C}\mathbf{A}\mathbf{X}\mathbf{B})^Td\mathbf{X}]^T + \mathbf{B}\mathbf{X}^T\mathbf{C}d\mathbf{A}\mathbf{X}\} + \text{其它与 } d\mathbf{X} \text{ 无关的项} \\
 &= \text{Tr}\{[(\mathbf{C}\mathbf{A}\mathbf{X}\mathbf{B})^T + \mathbf{B}\mathbf{X}^T\mathbf{C}\mathbf{A}]d\mathbf{X}\} + \text{其它与 } d\mathbf{X} \text{ 无关的项}
 \end{aligned}$$

因此：

$$\frac{\partial \text{Tr}(\mathbf{A}\mathbf{X}\mathbf{B}\mathbf{X}^T\mathbf{C})}{\partial \mathbf{X}} = (\mathbf{B}\mathbf{X}^T\mathbf{C}\mathbf{A})^T + \mathbf{C}\mathbf{A}\mathbf{X}\mathbf{B}$$

5. 用链式法则计算下列函数的梯度或Jacobian矩阵：

(1)  $f(z) = \log(1+z)$ ,  $z = \mathbf{x}^T\mathbf{x}$ ,  $\mathbf{x} \in \mathbb{R}^n$  ( $f$  为实值函数, 求  $\nabla_{\mathbf{x}}f$ , 即实值函数对向量的梯度) ;

(2)  $f(\mathbf{z}) = \sin(\mathbf{z})$ ,  $\mathbf{z} = \mathbf{A}\mathbf{x} + \mathbf{b}$ ,  $\mathbf{A} \in \mathbb{R}^{m \times n}$ ,  $\mathbf{x} \in \mathbb{R}^n$ ,  $\mathbf{b} \in \mathbb{R}^m$  ( $\sin(\cdot)$  逐元素作用于  $\mathbf{z}$ ,  $f$  为向量值函数, 求  $\frac{\partial f}{\partial \mathbf{x}^T}$ , 即向量值函数对向量的Jacobian矩阵) 。

解：

(1) 求  $\nabla_{\mathbf{x}}f$  (实值函数对向量的梯度)

由多元链式法则，实值复合函数的梯度满足： $\nabla_{\mathbf{x}} f = \frac{\partial f}{\partial z} \cdot \nabla_{\mathbf{x}} z$   
(注：标量对向量的梯度与标量对中间标量的导数乘积，遵循“标量×向量”的数乘规则)

第一步：计算  $\frac{\partial f}{\partial z}$   
 $f(z) = \log(1+z)$  是实值函数对实值变量的导数，故：  
 $\frac{\partial f}{\partial z} = \frac{1}{1+z} = \frac{1}{1+\mathbf{x}^T \mathbf{x}}$

第二步：计算  $\nabla_{\mathbf{x}} z$   
 $z = \mathbf{x}^T \mathbf{x}$  是实值函数对向量  $\mathbf{x}$  的梯度，由实值函数梯度公式：  
 $\nabla_{\mathbf{x}} z = 2\mathbf{x}$

第三步：合并得梯度  
 $\nabla_{\mathbf{x}} f = \frac{1}{1+\mathbf{x}^T \mathbf{x}} \cdot 2\mathbf{x} = \frac{2\mathbf{x}}{1+\mathbf{x}^T \mathbf{x}}$

(2) 求  $\frac{\partial f}{\partial \mathbf{x}^T}$  (向量值函数对向量的Jacobian矩阵)  
由向量值函数的链式法则：若  $f: \mathbb{R}^m \rightarrow \mathbb{R}^m$ ,  $\mathbf{z}: \mathbb{R}^n \rightarrow \mathbb{R}^m$ , 则  $\frac{\partial f}{\partial \mathbf{x}^T} = \frac{\partial f}{\partial \mathbf{z}^T} \cdot \frac{\partial \mathbf{z}}{\partial \mathbf{x}^T}$   
(注：Jacobian矩阵的乘积遵循“前一个函数的Jacobian × 后一个函数的Jacobian”，与  $\frac{\partial (x^{(n)})^T}{\partial x^{(1)}} = \prod_{i=1}^{n-1} \frac{\partial (x^{(i+1)})^T}{\partial x^{(i)}}$  一致)

第一步：计算  $\frac{\partial f}{\partial \mathbf{z}^T}$   
因  $\sin(\cdot)$  逐元素作用于  $\mathbf{z}$ , 即  $f_i = \sin(z_i)$  ( $i = 1, 2, \dots, m$ ) , 由Jacobian矩阵定义：  
 $\frac{\partial f_i}{\partial z_j} = \begin{cases} \cos(z_i) & i = j \\ 0 & i \neq j \end{cases}$   
故  $\frac{\partial f}{\partial \mathbf{z}^T} = \text{diag}(\cos(z_1), \cos(z_2), \dots, \cos(z_m))$  ( $m \times m$  对角矩阵) , 简记为  $\text{diag}(\cos(\mathbf{z}))$

第二步：计算  $\frac{\partial \mathbf{z}}{\partial \mathbf{x}^T}$   
 $\mathbf{z} = \mathbf{A}\mathbf{x} + \mathbf{b}$  是线性向量值函数，由线性函数Jacobian公式：  
 $\frac{\partial \mathbf{z}}{\partial \mathbf{x}^T} = \mathbf{A}$  ( $m \times n$  矩阵, 与  $\mathbf{A}$  维数一致)

第三步：合并得Jacobian矩阵  
 $\frac{\partial f}{\partial \mathbf{x}^T} = \text{diag}(\cos(\mathbf{z})) \cdot \mathbf{A} = \text{diag}(\cos(\mathbf{A}\mathbf{x} + \mathbf{b})) \cdot \mathbf{A}$

6. 我们考虑一个两层的全连接神经网络：

$$y = f(x) = \text{ReLU}(A_2(\text{ReLU}(A_1x + b_1)) + b_2)$$

其中

$$A_1 = \begin{pmatrix} 1 & 1 \\ 1 & -1 \\ -2 & 1 \end{pmatrix}, A_2 = \begin{pmatrix} 1 & -2 & 1 \\ 2 & -1 & 0 \end{pmatrix}, b_1 = \begin{pmatrix} 0 \\ -2 \\ -1 \end{pmatrix}, b_2 = \begin{pmatrix} -2 \\ -3 \end{pmatrix}$$

假设输入为  $x = \begin{pmatrix} 1 \\ 1 \end{pmatrix}$  , 并且对应的真实输出为  $y' = \begin{pmatrix} 1 \\ 0 \end{pmatrix}$  , 采用平方损失  $L = \frac{1}{2} \|y - y'\|_2^2$ 。

- (1) 计算函数  $L$  关于  $b_1, b_2$  的梯度。
- (2) 计算  $L$  关于  $A_1, A_2$  的梯度。

解：  
(1) 先计算前项过程：

$$A_1x + b_1 = \begin{pmatrix} 2 \\ -2 \\ -2 \end{pmatrix}, A_2(\text{ReLU}(A_1x + b_1)) + b_2 = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$$

故  $y = \begin{pmatrix} 0 \\ 1 \end{pmatrix}$  从而  $L = 1$ 。记

$$k = \text{ReLU}(A_1x + b_1) = \begin{pmatrix} 2 \\ 0 \\ 0 \end{pmatrix}$$

然后分别计算

$$\frac{\partial L}{\partial y} = \begin{pmatrix} -1 \\ 1 \end{pmatrix}, \frac{\partial y^T}{\partial b_2} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix}, \frac{\partial y^T}{\partial k} = \begin{pmatrix} 1 & 2 \\ -2 & -1 \\ 1 & 0 \end{pmatrix}, \frac{\partial k^T}{\partial b_1} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix}$$

所以有

$$\frac{\partial L}{\partial b_1} = \frac{\partial k^T}{\partial b_1} \frac{\partial y^T}{\partial k} \frac{\partial L}{\partial y} = \begin{pmatrix} 1 & 0 & 0 \\ 0 & 0 & 0 \\ 0 & 0 & 0 \end{pmatrix} \begin{pmatrix} 1 & 2 \\ -2 & -1 \\ 1 & 0 \end{pmatrix} \begin{pmatrix} -1 \\ 1 \end{pmatrix} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$$

$$\frac{\partial L}{\partial b_2} = \frac{\partial y^T}{\partial b_2} \frac{\partial L}{\partial y} = \begin{pmatrix} 1 & 0 \\ 0 & 1 \end{pmatrix} \begin{pmatrix} -1 \\ 1 \end{pmatrix} = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$$

(2) 由 (1) 可知  $\frac{\partial L}{\partial z_2} = \frac{\partial L}{\partial b_2} = \begin{pmatrix} -1 \\ 1 \end{pmatrix}$ ,  $\frac{\partial L}{\partial z_1} = \frac{\partial L}{\partial b_1} = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix}$ .

$$\frac{\partial L}{\partial A_2} = \frac{\partial L}{\partial z_2} k^T = \begin{pmatrix} -1 \\ 1 \end{pmatrix} \begin{pmatrix} 2 & 0 & 0 \end{pmatrix} = \begin{pmatrix} -2 & 0 & 0 \\ 2 & 0 & 0 \end{pmatrix}$$

$$\frac{\partial L}{\partial A_1} = \frac{\partial L}{\partial z_1} x^T = \begin{pmatrix} 1 \\ 0 \\ 0 \end{pmatrix} \begin{pmatrix} 1 & 1 \end{pmatrix} = \begin{pmatrix} 1 & 1 \\ 0 & 0 \\ 0 & 0 \end{pmatrix}$$