

《概率论与数理统计》习题

第一周 理论作业:

1.某城市中共发行3种报纸A, B, C.在这城市的居民中有45%订阅A报、35%订阅B报、30%订阅C报、10%同时订阅A报B报、8%同时订阅A报C报、5%同时订阅B报C报、3%同时订阅A, B, C报.求以下事件的概率:

(1)只订阅A报的;

(2)只订阅一种报纸的;

(3)至少订阅一种报纸的;

(4)不订阅任何一种报纸的.

(1)仍使用A, B, C分别表示订阅A, B, C报,则有 $P(A) = 0.45, P(B) = 0.35, P(C) = 0.3, P(AB) = 0.10, P(AC) = 0.08, P(BC) = 0.05, P(ABC) = 0.03$.

$P(\text{只订阅A报}) = P(\overline{AB}\overline{C}) = P(A - (B \cup C)) = P(A) - P(A(B \cup C))$
 $= P(A) - P(AB) - P(AC) + P(ABC) = 0.30$

(2)因为 $P(\text{只订阅一种报纸}) = P(\overline{AB}\overline{C}) + P(\overline{A}\overline{B}C) + P(\overline{A}B\overline{C})$

其中 $P(\overline{A}\overline{B}C) = P(C) - P(AC) - P(BC) + P(ABC) = 0.23$

$P(\overline{A}B\overline{C}) = P(B) - P(AB) - P(BC) + P(ABC) = 0.20$

所以

$P(\text{只订阅一种报纸}) = 0.30 + 0.23 + 0.20 = 0.73$

(3) $P(\text{至少订阅一种报纸}) = P(A \cup B \cup C) = P(A) + P(B) + P(C) - P(AB) - P(AC) - P(BC) + P(ABC) = 0.90$

(4) $P(\text{不订阅任何一种报纸}) = P(\overline{A \cup B \cup C}) = 1 - P(A \cup B \cup C) = 0.10$

2.证明: (1) $P(AB) \geq P(A) + P(B) - 1$

(2) $P(A_1 A_2 \cdots A_n) \geq P(A_1) + P(A_2) + \cdots + P(A_n) - (n - 1)$

(1)由 $1 \geq P(A \cup B) = P(A) + P(B) - P(AB)$,移项即得结论

(2)对n用数学归纳法,当 $n = 2$ 时,由(1)知结论成立.设 $n - 1$ 时结论成立, 即

$P(A_1 A_2 \cdots A_{n-1}) \geq P(A_1) + P(A_2) + \cdots + P(A_{n-1}) - (n - 2)$.

则由(1)知

$P(A_1 A_2 \cdots A_n)$

$= P((A_1 A_2 \cdots A_{n-1}) A_n) \geq P(A_1 A_2 \cdots A_{n-1}) + P(A_n) - 1$

$\geq P(A_1) + P(A_2) + \cdots + P(A_{n-1}) - (n - 2) + P(A_n) - 1$

$= P(A_1) + P(A_2) + \cdots + P(A_n) - (n - 1)$

3.反复掷四面骰子, 直到第一次(如果有的话)得到偶数面。这个实验的样本空间是多少?

a.任何有限序列形式为 $(a_1, a_2, \dots, a_n)$, 其中任意正整数, $a_1, a_2, \dots, a_{n-1}$ 属于1,3, a_n 属于2,4。

b.从未获得偶数。这样的结果是无限序列 $(a_1, a_2, \dots)$, 序列中的每个元素都属于1,3。

样本空间由上述两种类型的所有可能结果组成。

4.在8×8的棋盘上, 八个“车”被放置在不同的方格中, 放的所有可能的位置都是等概率的。找出所有“车”彼此安全的概率, 即没有包含超过一个“车”的行或列。

$$P = \frac{8!}{C_{64}^8} = \frac{8!}{\frac{64!}{8!56!}} = \frac{8!8!}{56!} = \frac{64 \times 49 \times 36 \times 25 \times 16 \times 9 \times 4}{56!}$$

5. 一个箱子里有n个球, 其中m个是红色的。

(1)我们随机选择k个球, 不放回(即在下次选择之前, 选定的球不会放回箱子里)。那么挑选出来k个球中i个是红球的概率是多少?

(2)我们随机选择k个球, 有放回(即在下次选择之前, 选定的球会放回箱子里)。那么挑选

出来 k 个球中 i 个是红球的概率是多少?

(1) 设事件A:不放回时, k 个球中有 i 个红球

$$P(A) = \frac{C_m^i C_{n-m}^{k-i}}{C_n^k}$$

(2) 设事件B:有放回时, k 个球中有 i 个红球

$$P(B) = C_k^i \left(\frac{m}{n}\right)^i \left(\frac{n-m}{n}\right)^{k-i}$$

6. 口袋中有10个球, 分别标有号码从1到10, 现从口袋中不放回地任取其中4个, 记下取出的球的号码, 试求:

(1) 4个球中最小号码为5的概率 (2) 4个球中最大号码为5的概率

(1) 设事件A:4个球中最小号码为5

即4个球中有1个球的号码为5, 剩下3个球的号码都比5大

$$P(A) = \frac{C_5^3}{C_{10}^4} = \frac{1}{21}$$

(2) 设事件B:4个球中最小号码为5

即4个球中有1个球的号码为5, 剩下3个球的号码都比5小

$$P(B) = \frac{C_4^3}{C_{10}^4} = \frac{2}{105}$$

7. 把 n 个“0”和 n 个“1”随机地排列, 求没有两个“1”连在一起的概率。

考虑 n 个“1”的放法: $2n$ 个位置上“1”占有 n 个位置, 所以共有 C_{2n}^n 种放法, 这是分母
没有两个“1”连在一起, 相当于在 n 个“0”之间及两头 (共 $n+1$ 个位置) 去放“1”, 这共有 C_{n+1}^n 种放法, 于是所求概率为

$$P = \frac{C_{n+1}^n}{C_{2n}^n}$$

第一周 实验作业

在区间(0,1)中随机地取两个数，求事件“两数之和小于 $7/5$ ”的概率。(分别用频率方法和几何方法确定概率)

(参考代码:答案不唯一)

```
#频率法
import numpy as np
iterations = 200000
times= 0
for i in range(iterations):
    a = np.random.random()
    b = np.random.random()
    if (a + b) < (7/5):
        times += 1
prob = times/iterations
print("%.2f" % prob)
#几何法
area = 1 - 0.6 * 0.6 / 2
print(area/1)
```

第二周 理论作业

1. 口袋中有一个球, 不知它的颜色是黑的还是白的. 现再往口袋中放入一个白球, 然后从口袋中任意取出一个, 发现取出的是白球, 试问口袋中原来那个球是白球的可能性为多少?

记事件A为“取出的是白球”, 事件B为: 原来那个球是白球“. 容易看出: $P(A|B) = 1, P(A|\bar{B}) = 0.5$, 另外由于对袋中原来的那个球的颜色一无所知, 故设 $P(B) = P(\bar{B}) = 0.5$ 是合理的. 由贝叶斯公式得

$$P(B|A) = \frac{P(B)P(A|B)}{P(B)P(A|B) + P(\bar{B})P(A|\bar{B})} = \frac{2}{3}$$

2. 假设只考虑天气的两种情况: 有雨或者无雨. 若已知今天的天气情况, 明天的天气保持不变的概率为 p , 变的概率为 $1 - p$. 设第一天无雨, 试求第 n 天也无雨的概率.

设事件 A_i 为“第 i 天无雨”, 记 $p_i = P(A_i), i = 1, 2, \dots$. 则有 $p_1 = 1$, 且

$$P(A_{i+1}|A_i), \quad P(A_{i+1}|\bar{A}_i) = 1 - p$$

所以由全概率公式得

$$p_n = pp_n + (1 - p)(1 - p_{n-1}) = (2p - 1)p_{n-1} + 1 - p, \quad n \geq 2.$$

得递推公式

$$p_n - \frac{1}{2} = (2p - 1)(p_{n-1} - \frac{1}{2}), \quad n \geq 2.$$

所以

$$p_n - \frac{1}{2} = (2p - 1)^{n-1}(p_1 - \frac{1}{2}),$$

将 $p_1 = 1$ 代入上式可得

$$p_n = \frac{1}{2} = (2p - 1)^{n-1}(\frac{1}{2})$$

由此得

$$p_n = \frac{1}{2}[1 + (2p - 1)^{n-1}], \quad n = 2, 3, \dots$$

3. 设 $P(A) > 0$, 试证:

$$P(B|A) \geq 1 - \frac{P(\bar{B})}{P(A)}$$

因为

$$P(AB) = P(A) + P(B) - P(A \cup B) \geq P(A) + P(B) - 1 = P(A) - P(\bar{B})$$

所以

$$P(B|A) = \frac{P(AB)}{P(A)} \geq \frac{P(A) - P(\bar{B})}{P(A)} = 1 - \frac{P(\bar{B})}{P(A)}.$$

4. 甲、乙两选手进行乒乓球单打比赛, 已知在每局中甲胜的概率为0.6, 乙胜的概率为0.4. 比赛可采用三局两胜制或五局三胜制, 试问哪一种比赛制度对甲更有利?

[(1)] 若采用三局两胜制, 则甲在下列两种情况下获胜:

A_1 = “甲胜前两局”

A_2 = “前两局甲乙各胜一局, 第三局甲胜”

所以得

$$P(A_1 \cup A_2) = P(A_1) + P(A_2) = 0.648$$

若采用五局三胜制，则甲在下列三种情况下获胜：

B_1 = "前三局甲胜"，

B_2 = "前三局中甲胜两局乙胜一局，第四局甲胜"，

B_3 = "前四局甲乙各胜两局，第五局甲胜"，

所以得

$$P(B_1 \cup B_2 \cup B_3) = 0.682$$


所以五局三胜制对甲更有利

5.对于事件 A 与事件 B ,假设 $P(B) > 0$, 证明 $P(A \cap B|B) = P(A|B)$.

通过条件概率的定义，有

$$P(A \cap B|B) = \frac{P(A \cap B \cap B)}{P(B)} = \frac{P(A \cap B)}{P(B)} = P(A|B)$$

6.现用噪声通信信道进行通信。信源通过噪声通信信道发送消息（一串符号）。每个符号为 0 或 1，概率分别为 p 和 $1-p$ ，且分别以概率 ϵ_0 和 ϵ_1 被错误接收，不同符号被错误接收的概率是独立的。



2. 图：二进制通信信道中的错误概率

(1)正确接收第 k 个符号的概率是多少？ (2)符号串1011被正确接收的概率是多少？ (3)为了提高可靠性，每个符号传输三次，接收的字符串按多数规则解码。换句话说，当且仅当接收到的三个符号串包含至少两个0（或分别为1）时，0（或1）被发送为000（或111），并且在接收器处被解码为0（或1）。0被正确解码的概率是多少？ (4)在使用(3)中的方案时， ϵ_0 取值为多少，0被正确解码的概率能有所提高？ (5)假设使用了第(3)中的方案。如果接收到的字符串为101，则符号为0的概率是多少？

[(1)]令 A 为发送 0 的事件。使用总概率定理，期望的概率是

$$P(A)(1 - \epsilon_0) + (1 - P(A))(1 - \epsilon_1) = p(1 - \epsilon_0) + (1 - p)(1 - \epsilon_1)$$

通过独立性，字符串 1011 被正确接收的概率为

$$(1 - \epsilon_0)(1 - \epsilon_1)^3$$

为了正确解码 0，接收到的字符串必须是 000,001,010 或 100。假设传输的字符串是 000，接收到 000 的概率是 $(1 - \epsilon_0)^3$ ，每个字符串 001,010 和 100 的概率是 $\epsilon_0(1 - \epsilon_0)^2$ 。因此，正确解码的概率为

$$3\epsilon_0(1 - \epsilon_0)^2 + (1 - \epsilon_0)^3$$

当符号为 0 时，使用和不使用 (3) 中的方案正确解码的概率分别是 $3\epsilon_0(1 - \epsilon_0)^2 + (1 - \epsilon_0)^3$ 和 $1 - \epsilon_0$ 因此，如果 (3) 中的方案提高了概率，有

$$3\epsilon_0(1 - \epsilon_0)^2 + (1 - \epsilon_0)^3 > (1 - \epsilon_0)$$

或

$$(1 - \epsilon_0)(1 + 2\epsilon_0) > 1$$

这相当于 $0 < \epsilon_0 < 1/2$ 。通过贝叶斯法则，有

$$\mathbf{P}(0 | 101) = \frac{\mathbf{P}(0)\mathbf{P}(101 | 0)}{\mathbf{P}(0)\mathbf{P}(101 | 0) + \mathbf{P}(1)\mathbf{P}(101 | 1)}$$

上式中所需的概率为

$$\mathbf{P}(0) = p, \quad \mathbf{P}(1) = 1 - p, \quad \mathbf{P}(101 | 0) = \epsilon_0^2 (1 - \epsilon_0), \quad \mathbf{P}(101 | 1) = \epsilon_1 (1 - \epsilon_1)^2$$

第三周 理论作业

1. 口袋中有5个球，编号为1,2,3,4,5. 从中任取3个，以 X 表示取出来的3个球中的最大号码.

(1) 试求 X 的分布列

X	3	4	5
P	0.1	0.3	0.6

(2) 写出 X 的分布函数，并作图.

$$F(x) = \begin{cases} 0, & x < 3, \\ 0.1, & 3 \leq x < 4, \\ 0.4, & 4 \leq x < 5, \\ 1, & x \geq 5 \end{cases}$$




图: X 的分布函数作图

2. 设连续随机变量 X 的分布函数为

$$F(x) = \begin{cases} 0, & x < 0, \\ Ax^2, & 0 \leq x < 1, \\ 1, & x \geq 1. \end{cases}$$

试求:

(1) 系数 A ;

由 $F(x)$ 的连续性:

$$1 = F(1) = \lim_{x \rightarrow 1-0} F(x) = \lim_{x \rightarrow 1-0} Ax^2 = A$$

解得 $A = 1$ (2) X 落在区间 $(0.3, 0.7)$ 内的概率;

$$P = F(0.7) - F(0.3) = (0.7)^2 - (0.3)^2 = 0.4$$

(3) X 的密度函数;

$$p(x) = F(x)' = \begin{cases} 2x, & 0 < x < 1, \\ 0, & \text{otherwise.} \end{cases}$$

3. 设连续随机变量 X 的密度函数 $p(x)$ 是一个偶函数, $F(x)$ 为 X 的分布函数, 求证对任意实数 $a > 0$, 有

(1) $F(-a) = 1 - F(a) = 0.5 - \int_0^a p(x)dx$;
 因为 $p(x)$ 是一个偶函数, 所以 $P(x) = p(-x)$, 且从

$$1 = \int_{-\infty}^{+\infty} p(x)dx = 2 \int_0^{+\infty} p(x)dx$$

可得

$$\int_0^{+\infty} p(x)dx = 0.5$$

在 $F(-a) = \int_{-\infty}^{-a} p(x)dx$ 中令 $x = -t$, 则

$$F(-a) = \int_{+\infty}^a p(t)(-dt) = \int_a^{+\infty} p(t)dt = 1 - F(a)$$

所以,

$$F(-a) = \int_a^{+\infty} p(t)dt = \int_0^{+\infty} p(t)dt - \int_0^a p(t)dt = 0.5 - \int_0^a p(x)dx$$

$$(2) P(|X| < a) = 2F(a) - 1;$$

$$P(|X| < a) = P(-a < X < a) = F(a) - F(-a)$$

$$= F(a) - [1 - F(a)] = 2F(a) - 1 \quad (3) P(|x| > a) = 2[1 - F(a)].$$

$$P(|X| > a) = P(X < -a) + P(X > a) = F(-a) + 1 - F(a)$$

$$1 - F(a) + 1 - F(a) = 2[1 - F(a)]$$

4. 麻省理工学院足球队计划在一个周末进行两场比赛。第一局不输的概率为0.4。第二局不输的概率为0.7, 与第一局无关。比赛不输的时候, 球队获胜或平局的概率是相同的, 两局比赛是相互独立的。麻省理工学院队获胜得2分, 平局得1分落败得分为0。给出足球队在周末获得的分数的分布列。

X	0	1	2	3	4
P	0.18	0.27	0.34	0.14	0.07

5. Alvin向半径为r的圆形目标投掷飞镖, 有可能落到目标中的任何一点。设X为Alvin的飞镖的落点与目标中心的距离。(1)计算X的概率密度函数, 均值和方差。(2)目标具有半径为t的内圆。如果 $X \leq t$, Alvin 得到 $S = 1/X$ 的分数。否则他的分数为 $S = 0$ 。求 S 的分布函数。同时, S 是连续随机变量吗?

[(1)]首先计算 X 的分布函数。对于 $x \in [0, r]$, 有

$$F_X(x) = P(X \leq x) = \frac{\pi x^2}{\pi r^2} = \left(\frac{x}{r}\right)^2$$

对于 $x < 0$, 有 $F_X(x) = 0$, 对于 $x > r$, 我们有 $F_X(x) = 1$ 。通过微分, 得到PDF

$$f_X(x) = \begin{cases} \frac{2x}{r^2}, & \text{if } 0 \leq x \leq r \\ 0, & \text{其他} \end{cases}$$

有

$$\mathbf{E}[X] = \int_0^r \frac{2x^2}{r^2} dx = \frac{2r}{3}$$

同时

$$\mathbf{E}[X^2] = \int_0^r \frac{2x^3}{r^2} dx = \frac{r^2}{2}$$

因此

$$\text{var}(X) = \mathbf{E}[X^2] - (\mathbf{E}[X])^2 = \frac{r^2}{2} - \frac{4r^2}{9} = \frac{r^2}{18}$$

当且仅当 $X \leq t$ 时, Alvin 在 $[1/t, \infty)$ 范围内得到为正的分数, 否则他得到 0 分。因此, 对于 $s \leq 0$, S 的分布函数为 $F_s(s) = 0$ 。

对于 $0 \leq s < 1/t$, 有

$$F_S(s) = \mathbf{P}(S \leq s) = \mathbf{P}(X \leq t)\mathbf{P}(S \leq s | X \leq t) + \mathbf{P}(X > t)\mathbf{P}(S \leq s | X > t)$$

有

$$\mathbf{P}(X \leq t) = \frac{t^2}{r^2}, \quad \mathbf{P}(X > t) = 1 - \frac{t^2}{r^2}$$

因为 $S = 0$, 当 $X > t$ 时

$$\mathbf{P}(S \leq s | X > t) = 1$$

此外,

$$\mathbf{P}(S \leq s | X \leq t) = \mathbf{P}(1/X \leq s | X \leq t) = \frac{\mathbf{P}(1/s \leq X \leq t)}{\mathbf{P}(X \leq t)} = \frac{\frac{\pi t^2 - \pi(1/s)^2}{\pi r^2}}{\frac{\pi t^2}{\pi r^2}} = 1 - \frac{1}{s^2 t^2}$$

结合上述方程, 可以得到

$$\mathbf{P}(S \leq s) = \frac{t^2}{r^2} \left(1 - \frac{1}{s^2 t^2} \right) + 1 - \frac{t^2}{r^2} = 1 - \frac{1}{s^2 r^2}$$

根据前面计算的结果, S 的分布函数为

$$F_S(s) = \begin{cases} 0, & \text{if } s < 0 \\ 1 - \frac{t^2}{r^2}, & \text{if } 0 \leq s < 1/t \\ 1 - \frac{1}{s^2 r^2}, & \text{if } 1/t \leq s \end{cases}$$

因为 F_S 在 $s = 0$ 处具有不连续性, 所以随机变量 S 不连续。

6. 假设你租了一个别墅, 租赁公司给你提供了 5 把钥匙, 5 把钥匙是用于打开公寓中 5 扇不同的门。你无法从这 5 把钥匙的外观来进行区分。于是, 为了打开前门, 你进行随机尝试。令 X 为直到你需要尝试的次数直到你成功打开前门。请写出在以下两种假设下, 求出 X 的概率分布列。

(a) 在你发现一枚钥匙无法打开门, 你做了一个记号, 之后你不会再尝试标记过的钥匙, 而在未标记的钥匙中等概率地选择。

2.

X	1	2	3	4	5
P	0.2	0.2	0.2	0.2	0.2

(b) 在每一次尝试中, 你等概率地选择每一把钥匙。

$$P(X = k) = 0.2 \times 0.8^{k-1}$$

7. 设 K 服从 $(1, 6)$ 上的均匀分布, 求方程 $x^2 + Kx + 1 = 0$ 有实根的概率。

解: 方程有实根的充要条件是:

$$\{K^2 - 4 \geq 0\} = \{K \leq -2\} \cup \{K \geq 2\}$$

而 $K \sim U(1, 6)$, 因此所求概率为

$$P(K \leq -2) + P(K \geq 2) = 0.8$$

8. 设随机变量 X 服从伽马分布 $Ga(2, 0.5)$, 试求 $P(X < 4)$
解: 伽马分布 $Ga(2, 0.5)$ 的密度函数为

$$p(x) = \begin{cases} \frac{0.5^2}{\Gamma(2)} x^{2-1} e^{-0.5x}, & x \geq 0, \\ 0, & x < 0. \end{cases}$$

由于 $\Gamma(2) = 1$, 因此所求概率为

$$P(X < 4) = \frac{1}{4} \int_0^4 x e^{-\frac{x}{2}} dx = 0.594$$

9. 某地区漏缴税款的比例 X 服从参数 $a = 2, b = 9$ 的贝塔分布, 试求此比例小于10%的概率及平均漏缴税款的比例。
贝塔分布 $Be(2, 9)$ 的密度函数为

$$p(x) = \begin{cases} \frac{\Gamma(2+9)}{\Gamma(2)\Gamma(9)} x^{2-1} (1-x)^{9-1}, & 0 < x < 1, \\ 0, & otherwise. \end{cases}$$

因为 $\Gamma(2+9) = 10!, \Gamma(2) = 1, \Gamma(9) = 8!$, 所以 $\frac{\Gamma(2+9)}{\Gamma(9)} = 90$, 因此

$$P(X < 0.1) = 90 \int_0^{0.1} x(1-x)^8 dx = 0.2639$$

$$E(X) = \frac{a}{a+b} = \frac{2}{11}$$

10. 假设一个随机变量 X , 其概率质量函数或概率密度函数(统称为概率函数)为 $p(x)$ 。
。设 $g(x)$ 为一个非常值函数。如果存在一个非零常数 c , 使得

$$p(x) = c \cdot g(x)$$

那么称 $g(x)$ 为概率函数的“核”。

例如: $X \sim N(0, 1)$, 其概率函数的“核”为 $\exp\{-x^2/2\}, x \in R$;
 $X \sim b(1, p)$, 其概率函数的“核”为 $p^x(1-p)^{1-x}, x = 0, 1$;

请指出以下函数是哪个随机变量的概率函数的核。

(a) $p^x(1-p)^{m-x}, x = 0, 1, 2, \dots, m$, 其中 p, m 是参数。

(b) $p^m(1-p)^{x-m}, x = m, m+1, \dots$, 其中 p, m 是参数。

(c) $x^p(1-x)^{m-p}, x \in (0, 1)$; 这里 p, m 是参数。

(d) $e^{-2\gamma x^2}, x \in R$, 这里 γ 是参数。

(e) $e^{-2\gamma x}, x \in R$, 这里 γ 是参数。

(f) $x^2 e^{-2\gamma x}, x \in R$, 这里 γ 是参数。

参考答案:

(a) $x \sim b(m, p)$

(b) $x \sim Nb(m, p)$

(c) $x \sim Be(p+1, m-p+1)$

(d) $x \sim N(0, \frac{1}{4\gamma})$

(e) $x \sim Exp(2\gamma)$

(f) $x \sim Ga(3, 2\gamma)$

11. 凯尔特人队和湖人队将进行共 n 场篮球赛的系列赛, 其中 n 是奇数。在每场比赛中, 凯尔特人队赢的概率为 p , 且每场比赛之间相互独立的。

- (a) 找出对于凯尔特人队来说 $n = 5$ 比 $n = 3$ 更好时的 p 的值。
 (b) 对(a)进行归纳, 即对于任何 $k > 0$, 找到 p 的值, 使其对于凯尔特人队来说, $n = 2k + 1$ 比 $n = 2k - 1$ 更好。

考虑 (b) 的一般情况, 证明 $p \geq 1/2$ 是 $n=2k+1$ 场比赛优于 $n=2k-1$ 场比赛的充要条件。为了证明这一点, 让 N 为凯尔特人队在前 $2k-1$ 场比赛中获胜的次数。如果 A 表示凯尔特人队以 $n=2k+1$ 获胜的事件, B 表示凯尔特人队以 $n=2k-1$ 获胜的事件, 那么

$$P(A) = P(N \geq k + 1) + P(N = k) \cdot (1 - (1 - p)^2) + P(N = k - 1) \cdot p^2$$

$$P(B) = P(N \geq k) = P(N = K) + P(N \geq k + 1)$$

因此,

$$\begin{aligned} P(A) - P(B) &= P(N = k - 1) \cdot p^2 - P(N = k) \cdot (1 - p)^2 \\ &= \binom{2k-1}{k-1} p^{k-1} (1-p)^k p^2 - \binom{2k-1}{k} (1-p)^2 p^k (1-p)^{k-1} \\ &= \frac{(2k-1)!}{(k-1)!k!} p^k (1-p)^k (2p-1) \end{aligned}$$

$P(A) \geq P(B)$ 时, 当且仅当 $p \geq 1/2$ 。
 因此, 更长的系列赛对篮球队来说更好。

第四周 理论作业

1. 设随机变量 X 的密度函数为

$$p(x) = \begin{cases} a + bx^2, & 0 \leq x \leq 1 \\ 0, & \text{其他.} \end{cases}$$

如果 $E(X) = 2/3$,求 a 和 b .

解 由 $\int_0^1 (a + bx^2)dx = 1$ 得

$$a + \frac{1}{3}b = 1$$

又

$$\frac{2}{3} = E(X) = \int_0^1 x(a + bx^2)dx$$

可得

$$\frac{1}{2}a + \frac{1}{4}b = \frac{2}{3}$$

联立求解: $a = \frac{1}{3}, b = 2$

2. 设随机变量 X 的分布函数为

$$F(x) = 1 - e^{-x^2}, x > 0$$

试求 $E(X)$ 和 $Var(X)$.

因为 X 为非负连续随机变量, 有

$$E(X) = \int_0^{+\infty} (1 - F(x))dx = \int_0^{+\infty} e^{-x^2} dx$$

令 $x = t/\sqrt{2}$

$$= \int_0^{+\infty} e^{-\frac{t^2}{2}} \frac{1}{\sqrt{2}} dt = \sqrt{\pi}/2$$

$$E(X^2) = \int_0^{+\infty} 2xe^{-x^2} dx = 1$$

由此得 $Var(X) = 1 - \pi/4$

3. 设随机变量 $X \sim U(a, b)$, 对 $k = 1, 2, 3, 4$, 求 $\mu_k = E(X^k)$ 与 $v_k = E(X - E(X))^k$. 进一步求此分布的偏度系数和峰度系数。

因为

$$E(X^k) = \int_a^b \frac{x^k}{b-a} dx = \frac{1}{b-a} \times \frac{b^{k+1} - a^{k+1}}{k+1}$$

所以

$$\begin{aligned}
\mu_1 &= E(X) = \frac{a+b}{2} \\
\mu_2 &= E(X^2) = \frac{1}{3}(a^2 + ab + b^2) \\
\mu_3 &= E(X^3) = \frac{1}{4}(a^3 + a^2b + ab^2 + b^3) \\
\mu_4 &= E(X^4) = \frac{1}{5}(a^4 + a^3b + a^2b^2 + ab^3 + b^4) \\
\nu_1 &= E(X - E(X)) = 0 \\
\nu_2 &= E(X - E(X))^2 = \frac{(b-a)^2}{12} \\
\nu_3 &= \mu_3 - 3\mu_2\mu_1 + 2\mu_1^3 = 0 \\
\nu_4 &= \mu_4 - 4\mu_3\mu_1 + 6\mu_2\mu_1^2 - 3\mu_1^4 = \frac{(b-a)^4}{80}
\end{aligned}$$

偏度系数和峰度系数分别为

$$\begin{aligned}
\beta_s &= \frac{\nu_3}{[\nu_2]^{\frac{3}{2}}} = 0 \\
\beta_k &= \frac{\nu_4}{\nu_2^2} - 3 = -1.2
\end{aligned}$$

4. 设随机变量 X 服从双参数韦布尔分布，其分布函数为

$$F(x) = 1 - \exp \left\{ - \left(\frac{x}{\eta} \right)^m \right\}, x > 0,$$

其中 $\eta > 0, m > 0$. 试写出该分布的 p 分位数 x_p 的表达式，且求出当 $m = 1.5, \eta = 1000$ 时的 $x_{0.1}, x_{0.5}, x_{0.8}$ 的值。因为 p 分位数 x_p 满足

$$1 - \exp \left\{ - \left(\frac{x}{\eta} \right)^m \right\} = p$$

解的

$$x_p = \eta [-\ln(1-p)]^{\frac{1}{m}}$$

将 $m = 1.5, \eta = 1000$ 代入上式可得

$$x_{0.1} = 223.08 \quad x_{0.5} = 783.22 \quad x_{0.8} = 1373.36.$$

第五周 理论作业

1. 已知随机变量 X 的密度函数为

$$p(x) = \frac{2}{\pi} \cdot \frac{1}{e^x + e^{-x}}, -\infty < x < +\infty$$

试求随机变量 $Y = g(X)$ 的概率分布, 其中

$$g(x) = \begin{cases} -1, & \text{当 } x < 0, \\ 1, & \text{当 } x \geq 0. \end{cases}$$

$p(x)$ 为偶函数, 可得 $P(X < 0) = P(\geq 0) = 0.5$

由此可得

$$P(Y = -1) = P(X < 0) = P(X \geq 0) = P(Y = 1) = 0.5$$

2. 设圆的直径服从区间 $(0, 1)$ 上的均匀分布, 求圆的面积的密度函数.
设圆的直径为 X , 则圆的面积 $Y = \pi X^2/4$, 而 X 的密度函数为

$$p(x) = \begin{cases} 1, & 0 < x < 1 \\ 0, & \text{其他.} \end{cases}$$

因为 $y = g(x) = \pi x^2/4$ 在区间 $(0, 1)$ 上为严格单调增函数, 其反函数为 $x = h(y) = \sqrt{4y/\pi}$, 且 $h'(y) = 1/\sqrt{\pi y}$, 所以圆面积 $Y = \pi X^2/4$ 的密度函数为

$$p(x) = \begin{cases} p_X(\sqrt{4y/\pi})|1/\sqrt{\pi y}|, & 0 < y < \pi/4 \\ 0, & \text{其他.} \end{cases}$$

即

$$p(x) = \begin{cases} \frac{1}{\sqrt{\pi y}}, & 0 < y < \pi/4 \\ 0, & \text{其他.} \end{cases}$$

3. 设随机变量 X 的密度函数为

$$p_X(x) = \begin{cases} \frac{3}{2}x^2, & -1 < x < 1, \\ 0, & \text{其他.} \end{cases}$$

试求下列随机变量的分布: (1) $Y_1 = 3X$; (2) $Y_2 = 3 - X$; (3) $Y_3 = X^2$.

(1)

$y = g(x) = 3x$ 在区间 $(-1, 1)$ 上为严格单调增函数

反函数: $x = h(y) = y/3$

$$p(x) = \begin{cases} p_X(y/3)|1/3|, & -3 < y < 3 \\ 0, & \text{其他.} \end{cases}$$

即

$$p(x) = \begin{cases} y^2/18, & -3 < y < 3 \\ 0, & \text{其他.} \end{cases}$$

(2)

$y = g(x) = 3-x$ 在区间 $(-1, 1)$ 上为严格单调减函数

反函数: $x = h(y) = 3-y$

$$p(x) = \begin{cases} p_X(3-y)|-1|, & 2 < y < 4 \\ 0, & \text{其他.} \end{cases}$$

即

$$p(x) = \begin{cases} \frac{3}{2}(3-y)^2, & 2 < y < 4 \\ 0, & \text{其他.} \end{cases}$$

(3)

因为 Y_3 的可能取值区间为 $(0,1)$ ，所以在区间 $(0,1)$ 外， Y_3 的密度函数为 $p_Y(y) = 0$ ，而当 $0 < y < 1$ 时， Y_3 的分布函数为

$$F_{Y_3}(y) = P(Y_3 \leq y) = P(X^2 \leq y) = F_X(\sqrt{y}) - F_X(-\sqrt{y})$$

上式两边关于 y 求导，得

$$P_Y(y) = P_X(\sqrt{y}) \frac{1}{2\sqrt{y}} + P_X(-\sqrt{y}) \frac{1}{2\sqrt{y}} = \frac{3}{2}\sqrt{y}$$

即

$$p(x) = \begin{cases} \frac{3}{2}\sqrt{y}, & 0 < y < 1 \\ 0, & \text{其他.} \end{cases}$$

4. 设 X 为随机变量，其取值范围为0到9，取值概率相等 均为 $1/10$.

(a) 求随机变量 $Y = X \bmod(3)$ 的分布列.

Y	0	1	2
P	0.4	0.3	0.3

(b) 求随机变量 $Y = 5 \bmod(X + 1)$ 的分布列.

Y	0	1	2	5
P	0.2	0.2	0.1	0.5

第五周 实验作业

1. 找到合适的Python函数, 求以下标准正态分布的分位数 x_α , 其中, $\alpha = 0.01, 0.025, 0.5, 0.1, 0.2, 0.25, 0.3, 0.4, 0.9$, 结果保留六位小数。

```
import scipy.stats as stats
quantiles = [0.01, 0.025, 0.5, 0.1, 0.2, 0.25,
             0.3, 0.4, 0.5, 0.6, 0.7, 0.75, 0.8,
             0.9, 0.95, 0.0975, 0.99]
for q in quantiles:
    x = stats.norm.ppf(q)
    print(f"x({q}) = {x:.6f}")
```

2. 利用Python生成均匀分布 $U(0, 1)$ 的随机数, 生成 10^6 个标准正态分布的伪随机数 $x_i, i = 1, 2, \dots, 10^6$ 。

(a) 绘制这 10^6 个伪随机数 $x_i, i = 1, 2, \dots, 10^6$ 的直方图 (注意: 直方图的面积为1), 并在同一张图片中绘制标准正态分布的密度函数。评述直方图和密度函数的关系。

```
import matplotlib.pyplot as plt
import numpy as np

U1=np.random.uniform(0,1,size=1000000)
U2=np.random.uniform(0,1,size=1000000)
plt.rcParams['axes.unicode_minus']=False
Y1=np.sqrt(-2 * np.log(U1)) * np.cos(2 * np.pi * U2)
plt.rcParams['font.sans-serif']=['SimHei']
plt.title("伪随机数生成的标准正态分布频率直方图与标准正态分布密度函数")
plt.ylabel("频率/组距")
plt.xlabel("样本")
bins=30
plt.hist(Y1,bins,density=True,edgecolor='black')
x=np.arange(-5,5,0.1)
sigma=1
u=0
y=np.multiply(np.power(np.sqrt(2 * np.pi) * sigma, -1),
np.exp(-np.power(x - u, 2) / 2 * sigma ** 2))
plt.plot(x,y)
plt.show()
```

频率分布直方图中横轴表示众多个连续变量离散化以后的区间, 这个区间的大小称为组距, 纵轴表示频率/组距。直方图是数值数据分布的精确图形表示。这是一个连续变量(定量变量)的概率分布的估计。概率密度函数用于描述连续型随机变量所服从的概率分布, 是概率计算的通用表达。换句话说, 频率分布直方图是频率的离散整合, 概率密度函数是频率的通用整合。从上述伪随机数生成的标准正态分布频率直方图 (面积为1) 与标准正态分布的密度函数可以看出, 在频率直方图中, 如果取每个样本组的中点并将其连成一条折线, 可以发现该折线与标准正态分布的密度函数几乎重合。这说明当频率分布直方图中组距趋近于零时, 上述折线就会无限趋近于一条光滑的曲线—总体密度曲线 (概率密度函数对应曲线)。也就是说, 概率密度函数是对应频率直方图的极限。

(b) 计算 $y_i = x_i^2, i = 1, 2, \dots, 10^6$ 。绘制这 10^6 个伪随机数 $y_i, i = 1, 2, \dots, 10^6$ 的直方图 (注意: 直方图的面积为1), 并在同一张图片中绘制卡方分布 $\chi^2(1)$ 的密度函数。评述直方图和密度函数的关系。

```
import matplotlib.pyplot as plt
import numpy as np
```

```

import scipy.stats as stats
U1=np.random.uniform(0,1,size=1000000)
U2=np.random.uniform(0,1,size=1000000)
plt.rcParams['axes.unicode_minus']=False
Y1=np.power(np.sqrt(-2 * np.log(U1)) * np.cos(2 * np.pi * U2),2)
plt.ylabel("频率/组距")
plt.xlabel("样本")
plt.rcParams["font.sans-serif"]=['SimHei']
plt.title("伪随机数生成的自由度为1的卡方分布频率直方图与自由度为1的卡方分布密度函数")
bins=40
plt.hist(Y1,bins,density=True,edgecolor='black')
plt.plot(np.linspace(0,15,100),stats.chi2.pdf(np.linspace(0,15,100),df=1))
plt.fill_between(np.linspace(0,15,100),
stats.chi2.pdf(np.linspace(0,15,100),df=1),alpha=0.15)
plt.show()

```

频率分布直方图中横轴表示众多个连续变量离散化以后的区间，这个区间的大小称为组距，纵轴表示频率/组距。直方图是数值数据分布的精确图形表示。这是一个连续变量(定量变量)的概率分布的估计。概率密度函数用于描述连续型随机变量所服从的概率分布，是概率计算的通用表达。换句话说，频率分布直方图是频率的离散整合，概率密度函数是频率的通用整合。从上述伪随机数生成的卡方分布频率直方图（面积为1）与卡方分布（自由度为1）的密度函数可以看出，在频率直方图中，如果取每个样本组的中点并将其连成一条折线，可以发现该折线与标准正态分布的密度函数几乎重合。这说明当频率分布直方图中组距趋近于零时，上述折线就会无限趋近于一条光滑的曲线—总体密度曲线（概率密度函数对应曲线）。也就是说，概率密度函数是对应频率直方图的极限。

第六周 理论作业

1. 口袋中有5个白球, 8个黑球, 从中不放回地一个接一个取出3个。如果第*i*次取出的是白球, 则令 $X_i = 1$, 否则令 $X_i = 0, i = 1, 2, 3$. 求

(a) (X_1, X_2, X_3) 的联合分布列;

$$\begin{aligned} P(X_1 = 0, X_2 = 0, X_3 = 0) &= 0.1958 \\ P(X_1 = 0, X_2 = 0, X_3 = 1) &= P(X_1 = 0, X_2 = 1, X_3 = 0) \\ &= P(X_1 = 1, X_2 = 0, X_3 = 0) = 0.1632 \\ P(X_1 = 0, X_2 = 1, X_3 = 1) &= P(X_1 = 1, X_2 = 0, X_3 = 1) \\ &= P(X_1 = 1, X_2 = 1, X_3 = 0) = 0.0932 \\ P(X_1 = 1, X_2 = 1, X_3 = 1) &= 0.0350 \end{aligned}$$

(b) (X_1, X_2) 的联合分布列

$$\begin{aligned} P(X_1 = 0, X_2 = 0) &= 14/39 \\ P(X_1 = 0, X_2 = 1) &= P(X_1 = 1, X_2 = 0) = 10/39 \\ P(X_1 = 1, X_2 = 1) &= 5/39 \end{aligned}$$

2. 设二维随机变量 (X, Y) 的联合密度函数为

$$p(x, y) = \begin{cases} 6(1-y), & 0 < x < y < 1, \\ 0, & \text{其他.} \end{cases}$$

(a) 求 $P(X > 0.5, Y > 0.5)$;

找 $p(x, y)$ 的非零区域与 $\{x > 0.5, y > 0.5\}$ 的交集

$$P(X > 0.5, Y > 0.5) = 6 \int_{0.5}^1 \int_{0.5}^y (1-y) dx dy = 1/8$$

(b) 求 $P(X < 0.5)$ 和 $P(Y < 0.5)$;

$$P(X < 0.5) = 6 \int_0^{0.5} \int_x^1 (1-y) dy dx = 7/8$$

$$P(Y < 0.5) = 6 \int_0^{0.5} \int_x^{0.5} (1-y) dy dx = 1/2$$

(c) 求 $P(X + Y < 1)$.

$$P(X + Y < 1) = 6 \int_0^{0.5} \int_x^{1-x} (1-y) dy dx = 3/4$$

3. 设随机变量 X 与 Y 相互独立, 其联合分布列如下, 试求联合分布列中的 a, b, c .

XY	y_1	y_2	y_3
x_1	a	$1/9$	c
x_2	$1/9$	b	$1/3$

由联合分布列的正则性

$$a = 1/18, b = 2/9, c = 1/6$$

XY	y_1	y_2	y_3	$P(X = x_i)$
x_1	a	$1/9$	c	$a + c + 1/9$
x_2	$1/9$	b	$1/3$	$b + 4/9$
$P(Y = y_j)$	$a + 1/9$	$b + 1/9$	$c + 1/3$	1

4. 设二维随机变量 (X, Y) 的联合密度函数为

$$p(x, y) = \begin{cases} 3x, & 0 \leq y < x \leq 1, \\ 0, & \text{其他.} \end{cases}$$

试求(1)边际密度函数 $p_X(x)$ 和 $p_Y(y)$; (2) X 与 Y 是否独立?

(1)当 $0 < x < 1$ 时, 有

$$p_X(x) = \int_{-\infty}^{+\infty} p(x, y) dy = \int_0^x 3x dy = 3x^2$$

其余情况, $p_X(x) = 0$

又因为当 $0 \leq y \leq 1$ 时, 有

$$p_Y(y) = \int_{-\infty}^{+\infty} p(x, y) dx = \int_y^1 3x dx = \frac{3}{2}(1 - y^2)$$

其余情况, $p_Y(y) = 0$

(2)因为 $p(x, y) \neq p_X(x)p_Y(y)$, 所以 X 与 Y 不独立.

5. 在长为 a 的线段的中点的两边随机地各取一点, 求两点间的距离小于 $a/3$ 的概率.
记 X 为线段中点左边所取点到端点0的距离, Y 为线段中点右边所取点到端点 a 的距离,
则 $X \sim U(0, a/2)$, $Y \sim U(a/2, a)$, 且 X 与 Y 相互独立, 它们的联合密度函数为

$$p(x, y) = \begin{cases} \frac{4}{a^2}, & 0 < x < \frac{a}{2}, \frac{a}{2} < y < a, \\ 0, & \text{其他.} \end{cases}$$

根据 $p(x, y)$ 的非零区域与 $\{|x - y| < a/3\}$ 的交集, 所求概率为

$$P(|Y - X| < \frac{a}{3}) = \int_{a/6}^{a/2} \int_{a/2}^{a/3+x} \frac{4}{a^2} dy dx = 2/9$$

6. 股票市场交易者购入100股A股票和200股B股票。设 X 和 Y 分别表示A股票和B股票的价格波动。在一段时间内, 假设 X 和 Y 的联合密度函数在整数集 x 和 y 上是一致的且满足

$$-2 \leq x \leq 4, \quad -1 \leq y - x \leq 1$$

(a) 求 X 和 Y 的边缘密度函数以及均值.

(b) 求该交易者获取利润的均值.

解: (a) 该区域有21个整数对 (x, y)

$$R = \{(x, y) \mid -2 \leq x \leq 4, -1 \leq y - x \leq 1\}$$

所以, X 和 Y 的联合密度函数为

$$p_{X,Y}(x, y) = \begin{cases} 1/21, & \text{if } (x, y) \text{ is in } R, \\ 0, & \text{otherwise.} \end{cases}$$

对于 $[-2, 4]$ 范围内的每个 x , 都有三个可能的 Y 值。因此, 有

$$p_X(x) = \begin{cases} 3/21, & \text{if } x = -2, -1, 0, 1, 2, 3, 4, \\ 0, & \text{otherwise} \end{cases}$$

X的均值是范围[-2,4]的中点:

$$\mathbf{E}[X] = 1.$$

Y的边缘密度函数通过表格法获得, 于是有

$$p_Y(y) = \begin{cases} 1/21, & \text{if } y = -3 \\ 2/21, & \text{if } y = -2 \\ 3/21, & \text{if } y = -1, 0, 1, 2, 3 \\ 2/21, & \text{if } y = 4 \\ 1/21, & \text{if } y = 5 \\ 0, & \text{otherwise.} \end{cases}$$

Y的均值为

$$\mathbf{E}[Y] = \frac{1}{21} \cdot (-3 + 5) + \frac{2}{21} \cdot (-2 + 4) + \frac{3}{21} \cdot (-1 + 1 + 2 + 3) = 1$$

(b)利润可知为

$$P = 100X + 200Y$$

因此

$$\mathbf{E}[P] = 100 \cdot \mathbf{E}[X] + 200 \cdot \mathbf{E}[Y] = 100 \cdot 1 + 200 \cdot 1 = 300$$

第七周 理论作业

1. 求掷 n 颗骰子出现点数之和的数学期望与方差.

记 X_i 为第 i 颗骰子出现的点数, $i = 1, 2, \dots, n$,则 $X_1, X_2, \dots, X_n$ 独立同分布, 其共同的分布列为

X_i	1	2	3	4	5	6
P	1/6	1/6	1/6	1/6	1/6	1/6

所有

$$E(X_i) = \frac{7}{2}, Var(X_i) = \frac{35}{12}$$

由此得

$$E\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n E(X_i) = \frac{7n}{2}$$

$$Var\left(\sum_{i=1}^n X_i\right) = \sum_{i=1}^n Var(X_i) = \frac{35n}{12}$$

2. 设二维随机变量 (X, Y) 的联合密度函数为

$$p(x, y) = \begin{cases} 1, & |y| < x, 0 < x < 1, \\ 0, & \text{其他.} \end{cases}$$

求 $E(X), E(Y), Cov(X, Y)$

$$E(X) = \int_0^1 \int_{-x}^x x dy dx = \frac{2}{3}$$

$$E(Y) = \int_0^1 \int_{-x}^x y dy dx = 0$$

$$E(XY) = \int_0^1 \int_{-x}^x xy dy dx = 0$$

$$Cov(X, Y) = E(XY) - E(X)E(Y) = 0$$

3. 设随机变量 X 有密度函数 $p(x)$, 且密度函数 $p(x)$ 是偶函数, 假定 $E|X|^3 < +\infty$.证明: X 与 $Y = X^2$ 不相关、但不独立.

证明:

因为 $E(X) = E(X^3) = 0$,所以 $Cov(X, X^2) = 0$,这表明: X 与 $Y = X^2$ 不相关.为证明 X 与 Y 不相互独立,特给定 $a > 0$, 使得 $P(X \leq a) < 1$.现考查如下特定事件的概率

$$P(X \leq a, X^2 \leq a^2) = P(-a \leq X \leq a)$$

$$> P(X \leq a)P(-a \leq X \leq a)$$

$$= P(X \leq a)P(X^2 \leq a^2)$$

所以 X 与 $Y = X^2$ 不独立.

4. 如今有四个随机变量: W, X, Y, Z . 且满足

$$E[W] = E[X] = E[Y] = E[Z] = 0,$$

$$Var(W) = Var(X) = Var(Y) = Var(Z) = 1.$$

假设 W, X, Y, Z 是两两不相关的。求 R, S 的相关系数 $\rho(R, S)$ 以及 R, T 的相关系数 $\rho(R, T)$.

其中 $R = W + X, S = X + Y, T = Y + Z$.

解: 可知

$$\text{cov}(R, S) = \mathbf{E}[RS] - \mathbf{E}[R]\mathbf{E}[S] = \mathbf{E}[WX + WY + X^2 + XY] = \mathbf{E}[X^2] = 1$$

并且

$$\mathrm{var}(R) = \mathrm{var}(S) = 2$$

因此

$$\rho(R, S) = \frac{\mathrm{cov}(R, S)}{\sqrt{\mathrm{var}(R) \mathrm{var}(S)}} = \frac{1}{2}$$

又已知

$$\mathrm{cov}(R, T) = \mathbf{E}[RT] - \mathbf{E}[R]\mathbf{E}[T] = \mathbf{E}[WY + WZ + XY + XZ] = 0$$

因此

$$\rho(R, T) = 0$$

第八周 理论作业

1. 设 X 和 Y 是相互独立的随机变量, 且 $X \sim \text{Exp}(\lambda), Y \sim \text{Exp}(\mu)$. 如果定义随机变量 Z 如下

$$Z = \begin{cases} 1, & \text{当 } X \leq Y, \\ 0, & \text{当 } X > Y. \end{cases}$$

求 Z 的分布列.

Z	0	1
P	$\frac{\mu}{\lambda+\mu}$	$\frac{\lambda}{\lambda+\mu}$

2. 设随机变量 X 和 Y 独立同分布, 其密度函数为

$$p(x) = \begin{cases} e^{-x}, & x > 0, \\ 0, & x \leq 0. \end{cases}$$

- (a) 求 $U = X + Y$ 与 $V = X/(X + Y)$ 的联合密度函数 $p_{U,V}(u, v)$;

反函数: $x = uv, y = u(1 - v)$

变换的雅可比行列式: $J = -u$

在 (U, V) 的可能取值范围内 $\{u > 0, 0 < v < 1\}$ 内, 有

$$p_{U,V}(u, v) = p_X(uv)p_Y(u(1 - v))|-u| = ue^{-u}$$

- (b) 以上的 U 与 V 独立吗?

分别求 U 与 V 的边际密度函数

$$p_U(u) = ue^{-u}, u > 0$$

$$p_V(v) = 1, 0 < v < 1$$

所以由 $p_{U,V}(u, v) = p_U(u)p_V(v)$, 知 U 与 V 相互独立.

3. 设随机变量 $X_1, X_2, \dots, X_n$ 相互独立, 且 $X_i \sim \text{Exp}(\lambda_i)$, 试证

$$P(X_i = \min\{X_1, X_2, \dots, X_n\}) = \frac{\lambda_i}{\lambda_1 + \lambda_2 + \dots + \lambda_n}$$

证明:

$(X_1, X_2, \dots, X_n)$ 的联合密度为

$$p(x_1, x_2, \dots, x_n) = \prod_{j=1}^n \lambda_j e^{-\lambda_j x_j}$$

而事件

$$\{X_i = \min\{X_1, X_2, \dots, X_n\}\}$$

$= \{X_1 \geq X_i, \dots, X_{i-1} \geq X_i, 0 < X_i < +\infty, X_{i+1} \geq X_i, \dots, X_n \geq X_i\}$, 从而该事件的概率为

$$\begin{aligned} & P(X_i = \min\{X_1, X_2, \dots, X_n\}) \\ &= \int_0^{+\infty} \int_{x_i}^{+\infty} \dots \int_{x_i}^{+\infty} \int_{x_i}^{+\infty} \dots \int_{x_i}^{+\infty} \prod_{j=1}^n \lambda_j e^{-\lambda_j x_j} dx_1 \dots dx_{i-1} dx_{i+1} \dots dx_n dx_i \\ &= \int_0^{+\infty} \lambda_i e^{-(\lambda_1 + \dots + \lambda_n)x_i} dx_i = \frac{\lambda_i}{\lambda_1 + \lambda_2 + \dots + \lambda_n}. \end{aligned}$$

4. 在某一天, 你的高尔夫球得分在101到110之间, 独立于其他天且概率均为0.1。为了提高自己的分数, 你决定在三个不同的日子里进行比赛, 并取 X_1, X_2, X_3 三天中的最低分数作为自己的分数 X 。

(a) 计算 X 的概率质量函数。

(b) 三天的比赛让你的期望成绩改变了多少?

解: (a) 随机变量 X 的可能取值为10个数字101, $\dots$, 110, 概率密度函数由下式给出:

$$p_X(k) = \begin{cases} \mathbf{P}(X > k-1) - \mathbf{P}(X > k), & \text{if } k = 101, \dots, 110 \\ 0 & \text{otherwise} \end{cases}$$

已知 $\mathbf{P}(X > 100) = 1$ 并且对于 $k = 101, \dots, 110$ 有

$$\begin{aligned} \mathbf{P}(X > k) &= \mathbf{P}(X_1 > k, X_2 > k, X_3 > k) \\ &= \mathbf{P}(X_1 > k) \mathbf{P}(X_2 > k) \mathbf{P}(X_3 > k) \\ &= \frac{(110-k)^3}{10^3} \end{aligned}$$

因此

$$p_X(k) = \begin{cases} \frac{(111-k)^3 - (110-k)^3}{10^3}, & \text{if } k = 101, \dots, 110 \\ 0, & \text{otherwise} \end{cases}$$

(另一种解决方案基于累积分布函数的概念, 将在第3章中介绍。)

(b) 由于 X_i 在 $[101, 110]$ 范围内的整数上均匀分布, 因此 $\mathbf{E}[X_i] = (101 + 110)/2 = 105.5$ 。 X 的均值为

$$\mathbf{E}[X] = \sum_{k=-\infty}^{\infty} k \cdot p_X(k) = \sum_{k=101}^{110} k \cdot p_X(k) = \sum_{k=101}^{110} k \cdot \frac{(111-k)^3 - (110-k)^3}{10^3}$$

上述表达式可计算为103.025。因此, 期望成绩提高 $105.5 - 103.025 = 2.475$ 。

5. 一射手单发命中目标的概率为 p ($0 < p < 1$), 射击进行到命中目标两次为止。设 X 为第一次命中目标所需的射击次数, Y 为总共进行的射击次数, 求 (X, Y) 的联合分布和条件分布。
解: 只论命中与不命中的试验是伯努利试验。在一伯努利试验序列中, 首次命中的射击次数 X 服从几何分布 $Ge(p)$, 即

$$P(X = x) = (1-p)^{x-1} p, \quad x = 1, 2, \dots,$$

其中 p 为命中概率, 第二次命中目标的射击次数 Y 服从负二项分布 $Nb(2, p)$, 即

$$P(Y = y) = \binom{y-1}{1} (1-p)^{y-2} \cdot p^2, \quad y = 2, 3, \dots$$

由于 X 与 $Y - X$ 相互独立, 所以条件分布

$$\begin{aligned} P(Y = y | X = x) &= P(Y - X = y - x | X = x) \\ &= P(Y - X = y - x) = (1-p)^{y-x-1} \cdot p, \\ &\quad x = 1, 2, \dots, y-1 \quad y = 2, 3, \dots \end{aligned}$$

从而 (X, Y) 的联合分布列为

$$\begin{aligned} P(X = x, Y = y) &= P(X = x) P(Y = y | X = x) \\ &= P(X = x) P(Y - X = y - x) \end{aligned}$$

$$\begin{aligned}
&= (1-p)^{x-1} \cdot p \cdot 1 - p^{y-x-1} \cdot p \\
&= (1-p)^{y-2} p^2, \\
&x = 1, 2, \dots, y-1 \quad y = 2, 3, \dots.
\end{aligned}$$

另一条件分布

$$\begin{aligned}
P(X=x|Y=y) &= \frac{P(X=x, Y=y)}{P(Y=y)} \\
&= \frac{(1-p)^{y-2} \cdot p^2}{(y-1)(1-p)^{y-2} \cdot p^2} = \frac{1}{y-1} \\
&y = 2, 3, \dots.
\end{aligned}$$

6. 随机变量 X 服从 $(1, 2)$ 上的均匀分布, 在 $X = x$ 的条件下, 随机变量 Y 的条件分布是参数为 x 的指数分布, 证明: XY 服从参数为1的指数分布.

证: 因为 $X \sim U(1, 2), Y|X=x \sim \text{Exp}(x)$, 所以

$$p(x, y) = p_X(x)p(y|x) = xe^{-xy}, \quad 1 < x < 2, y > 0.$$

令 $U = XY, V = X$, 则 $u = xy, v = x$ 的逆变换为 $x = v, y = u/v$, 计算雅可比行列式 $J = -1/v$.

所以 (U, V) 的联合密度函数为

$$P_{U,V}(u, v) = P_{X,Y}(v, u/v) | -1/v | = ve^{-vu/v} 1/v = e^{-u}, \quad 1 < v < 2, u > 0.$$

由此的 $U = XY$ 的边际密度函数为

$$P_U(u) = \int_1^2 e^{-u} dv = e^{-u}, \quad u > 0.$$

即 $U = XY$ 服从参数为1的指数分布.

第九周 理论作业

1. 设以下所涉及的数学期望均存在, 试证:

- (a) $E[g(X)Y|X] = g(X)E(Y|X)$;
由 $E(g(X)Y|X = x) = g(x)E(Y|X = x)$, 知 $E(g(X)Y|X) = g(X)E(Y|X)$
- (b) $E(XY) = E[XE(Y|X)]$;
因为 $E(XY) = E[E(XY|X)]$, 又由(1)知 $E(XY|X) = XE(Y|X)$, 所以有 $E(XY) = E[X \cdot E(Y|X)]$.
- (c) $Cov[X, E(Y|X)] = Cov(X, Y)$.
证 $Cov[X, E(Y|X)] = E[X \cdot E(Y|X)] - E(X) \cdot E(Y) = E(XY) - E(X) \cdot E(Y) = Cov(X, Y)$.

2. 设 X 是一个连续随机变量, 其密度函数为

$$p_X(x) = \begin{cases} x/4, & 1 < x \leq 3 \\ 0, & \text{其他.} \end{cases}$$

令事件

$$A = \{X \geq 2\}$$

- (a) 求 $E(X)$, $P(A)$, $p_{X|A}(x)$ 以及 $E(X|A)$;
- (b) 令 $Y = X^2$. 求 $E(Y)$ 和 $Var(Y)$.

解: (a) $E(X) = \frac{13}{6}$, $P(A) = \frac{5}{8}$, $p_{X|A}(x) = \begin{cases} \frac{2}{5}x, & 2 \leq x \leq 3 \\ 0, & \text{其他.} \end{cases}$, $E(X|A) = \frac{38}{15}$
(b) $E(Y) = 5$, $Var(Y) = \frac{16}{3}$

3. Pat 和 Nat 将要约会, 他们所有的约会都安排在晚上9点开始。Nat 总是在晚上9点准时到达。Pat 非常混乱, 到达的时间在晚上8点到晚上10点之间均匀分布。设 X 表示从晚上8点到 Pat 到达的时间之间的小时数。如果 Pat 在晚上9点之前到达, 他们的约会将持续整整3个小时。如果 Pat 在晚上9点之后到达, 他们约会的持续时间将在 0 到 $3-X$ 小时之间均匀分布。约会从他们见面的时候开始。当 Pat 迟到时, Nat 会感到生气, 在 Pat 第二次约会迟到超过45分钟后, Nat 将结束这段关系。所有约会均独立于任何其他约会。

- (a) Nat 等待 Pat 到达的期望小时数是多少?
- (b) 任一约会的期望持续时间是多少?
- (c) 他们分手前的期望约会次数是多少?

解: (a) 设 W 为 Nat 等待的小时数, 则有

$$E[X] = P(0 \leq X \leq 1)E[W|0 \leq X \leq 1] + P(X > 1)E[W|X > 1]$$

因为只有当 $X \geq 1$ 时 $W \geq 0$, 所以

$$E[W] = P(X > 1)E[W|X > 1] = \frac{1}{2} \cdot \frac{1}{2} = \frac{1}{4}$$

(b) 设 D 为约会的持续时间。可知 $E[D|0 \leq X \leq 1] = 3$ 。那么, 当 $X \geq 1$ 时, 对于给定 X 的 D 的条件期望为 $(3-X)/2$ 。因此, 使用迭代期望定律可知,

$$E[D|X > 1] = E[E[D|X]|X > 1] = E\left[\frac{3-X}{2} | X > 1\right]$$

因此

$$\begin{aligned}\mathbf{E}[D] &= \mathbf{P}(0 \leq X \leq 1)\mathbf{E}[D \mid 0 \leq X \leq 1] + \mathbf{P}(X > 1)\mathbf{E}[D \mid X > 1] \\&= \frac{1}{2} \cdot 3 + \frac{1}{2} \cdot \mathbf{E}\left[\frac{3-X}{2} \mid X > 1\right] \\&= \frac{3}{2} + \frac{1}{2} \left(\frac{3}{2} - \frac{\mathbf{E}[X \mid X > 1]}{2}\right) \\&= \frac{3}{2} + \frac{1}{2} \left(\frac{3}{2} - \frac{3/2}{2}\right) \\&= \frac{15}{8}\end{aligned}$$

(c) Pat迟到超过45分钟的概率是 $1/8$ 。分手前的约会数是参数为 $1/8$ 的两个几何分布随机变量之和，其期望值为 $2 \cdot 8 = 16$ 。

概率论与数理统计 10 至 16 周习题参考答案

第 10 周习题

随机变量序列的收敛性部分

第一题

问题

设 $D(x)$ 为退化的分布函数

$$D(x) = \begin{cases} 0 & x < 0 \\ 1 & x \geq 0 \end{cases}$$

试问下列分布函数列的极限函数是否仍是分布函数? (其中 $n = 1, 2, \dots$)

$$(1) D_1(x) = \lim_{n \rightarrow \infty} D(x+n)$$

$$(2) D_2(x) = \lim_{n \rightarrow \infty} D(x+1/n)$$

$$(3) D_3(x) = \lim_{n \rightarrow \infty} D(x-1/n)$$

解答

(1) 因为此时的极限函数为 $G(x) = 1, -\infty < x < +\infty$, 不满足分布函数的基本性质: $\lim_{x \rightarrow -\infty} F(x) = 0$ 所以不是分布函数.

(2) 因为此时的极限函数为

$$G(x) = \begin{cases} 0, & x < 0, \\ 1, & x \geq 0. \end{cases}$$

所以是分布函数.

(3) 因为此时的极限函数为

$$G(x) = \begin{cases} 0, & x \leq 0, \\ 1, & x > 0. \end{cases}$$

不满足分布函数的右连续性, 所以不是分布函数.

第二题

问题

设 $X_1, X_2, \dots$ 是在区间 $[-1, 1]$ 上均匀分布的独立随机变量. 试证明以下每种情况下的序列 $Y_1, Y_2, \dots$ 依概率收敛, 并指出收敛值为多少?

1. $Y_n = X_n/n$.
2. $Y_n = (X_n)^n$
3. $Y_n = X_1 \cdot X_2 \cdots X_n$
4. $Y_n = \max\{X_1, \dots, X_n\}$

解答

在 (a),(b),(c) 情况下, 我们证明 Y_n 在概率上收敛到 0. 在 (d) 的情况下, 我们证明 Y_n 在概率上收敛到 1.

(a) 对于任意的 $\epsilon > 0$, 可知

$$\mathbf{P}(|Y_n| \geq \epsilon) = 0$$

对于所有的 n 有 $1/n < \epsilon$, 因此 $\mathbf{P}(|Y_n| \geq \epsilon) \rightarrow 0$.

(b) 对于所有的 $\epsilon \in (0, 1)$, 可知

$$\mathbf{P}(|Y_n| \geq \epsilon) = \mathbf{P}(|X_n|^n \geq \epsilon) = \mathbf{P}(X_n \geq \epsilon^{1/n}) + \mathbf{P}(X_n \leq -\epsilon^{1/n}) = 1 - \epsilon^{1/n}$$

并且右边的两项收敛到 0, 因为 $\epsilon^{1/n} \rightarrow 1$.

(c) 由于 $X_1, X_2, \dots$ 是独立的随机变量, 则

$$\mathbf{E}[Y_n] = \mathbf{E}[X_1] \cdots \mathbf{E}[X_n] = 0$$

又因为

$$\text{var}(Y_n) = \mathbf{E}[Y_n^2] = \mathbf{E}[X_1^2] \cdots \mathbf{E}[X_n^2] = \text{var}(X_1)^n = \left(\frac{4}{12}\right)^n$$

因此 $\text{var}(Y_n) \rightarrow 0$. 因为所有的 Y_n 都有 0 作为公共均值, 所以从切比雪夫不等式可以得出 Y_n 在概率上收敛到 0.

(d) 对于所有的 $\epsilon \in (0, 1)$, 利用 $X_1, X_2, \dots$ 的独立性可知,

$$\begin{aligned}\mathbf{P}(|Y_n - 1| \geq \epsilon) &= \mathbf{P}(\max\{X_1, \dots, X_n\} \geq 1 + \epsilon) + \mathbf{P}(\max\{X_1, \dots, X_n\} \leq 1 - \epsilon) \\ &= \mathbf{P}(X_1 \leq 1 - \epsilon, \dots, X_n \leq 1 - \epsilon) \\ &= (\mathbf{P}(X_1 \leq 1 - \epsilon))^n \\ &= \left(1 - \frac{\epsilon}{2}\right)^n\end{aligned}$$

因此 $\mathbf{P}(|Y_n - 1| \geq \epsilon) \rightarrow 0$.

大数定律部分

第三题

问题

在伯努利试验中, 事件 A 出现的概率为 p , 令

$$X_n = \begin{cases} 1, & \text{若在第 } n \text{ 次及第 } n+1 \text{ 次试验中 } A \text{ 都出现,} \\ 0, & \text{其他.} \end{cases}$$

证明: $\{X_n\}$ 服从大数定律

解答

证 X_n 为同分布随机变量序列, 其共同分布为

X_n	0	1
P	$1-p^2$	p^2

且 $E(X_n) = E(X_n^2) = p^2$, 从而 $Var(X_n) = p^2(1-p^2) \leq 1$, 又当 $|i-j| \geq 2$ 时, X_i 与 X_j 独立, 所以

$$\frac{1}{n^2} Var\left(\sum_{i=1}^n X_i\right) = \frac{1}{n^2} \left[\sum_{i=1}^n Var(X_i) + 2 \sum_{i=1}^{n-1} Cov(X_i, X_{i+1}) \right].$$

又因为

$$|Cov(X_i, X_{i+1})| \leq \sqrt{Var(X_i)} \sqrt{Var(X_{i+1})} = p^2(1-p^2),$$

于是有

$$\frac{1}{n^2} Var\left(\sum_{i=1}^n X_i\right) \leq \frac{1}{n^2} [np^2(1-p^2) + 2(n-1)p^2(1-p^2)] \rightarrow 0 \quad (n \rightarrow \infty),$$

即马尔可夫条件成立, 故 X_n 服从大数定律.

第四题

问题

为了估计众多人口中吸烟人数的真实比例 f , 阿尔文随机选取 n 人作为样本. 估算值 M_n 是通过将样本中吸烟者的数量 S_n 除以 n 得到的, 即 $M_n = \frac{S_n}{n}$. 阿尔文选择样本容量 n 作为能使以下切比雪夫不等式成立的最小可能值

$$P(|M_n - f| \geq \epsilon) \leq \delta$$

其中, ϵ 和 δ 是预先设定的误差. 请指出切比雪夫不等式中的 n 值在下列情况下会如何变化

1. ϵ 的值减少到其原始值的一半.
2. 概率 δ 降低到其原始值的一半.

解答

根据切比雪夫不等式可知:

$$\mathbf{P}(|M_n - f| \geq \epsilon) \leq \frac{1}{4n\epsilon^2}$$

- (a) 如果 ϵ 减少到其原始值的一半, 并且为了保持界限 $1/(4n\epsilon^2)$ 恒定, 样本大小 n 必须增大四倍.
- (b) 如果误差概率 δ 要降低到 $\delta/2$, 同时保持 ϵ 不变, 则样本量必须加倍.

中心极限定理部分

第五题

问题

计算机在进行加法运算时对每个加数取整数 (取最为接近与它的整数). 设所有的取整误差是相互独立的, 且它们都服从 $(-0.5, 0.5)$ 上的均匀分布.

1. 若将 1500 个数相加, 求误差总和的绝对值超过 15 的概率;
2. 最多几个数加在一起可使得误差总和的绝对值小于 10 的概率不小于 90%?

解答

设 X_i 为第 i 个加数的取整误差, 则

$$X_i \sim U(-0.5, 0.5); E(X_i) = 0; Var(X_i) = \frac{1}{12}$$

(1) 可得 $E(\sum_{i=1}^{1500} X_i) = 0$, $Var(\sum_{i=1}^{1500} X_i) = 125$, 所以,

$$P(|\sum_{i=1}^{1500} X_i| > 15) = 2 - 2\phi(\frac{15}{\sqrt{125}}) = 2 - 2\phi(1.34) = 0.1802.$$

(2) 由题意可得:

$$P(|\sum_{i=1}^{1500} X_i| < 10) \geq 90\%$$

利用林德伯格-莱维中心极限定理, 可得:

$$2\phi\left(\frac{10}{\sqrt{n/12}}\right) - 1 \geq 0.9$$

查表可得,

$$\frac{20\sqrt{3}}{\sqrt{n}} \geq 1.645$$

所以, $n \leq 443.45$. 因此, 最多 443 个数加在一起可使得误差总和的绝对值小于 10 的概率不小于 90%.

第六题

问题

某产品的合格品率为 99%, 问包装箱中应该装多少个此种产品, 才能有 95% 的可能性使每箱中至少有 100 个合格产品.

解答

设包装箱中装有 n 个产品, 其中合格品数记为 X , 则有 $X \sim b(n, 0.99)$. 下求 n , 使

$$P(X < 100) \leq 0.05$$

成立. 利用二项分布的正态近似, 可得

$$\phi\left(\frac{100 + 0.5 - 0.99n}{\sqrt{0.99 \times 0.01 \times n}}\right) \leq 0.05$$

查表可得,

$$\frac{100.5 - 0.99n}{0.0995\sqrt{n}} \leq -1.645$$

由此解得 $n > 103.19$, 即每箱装有 104 个产品, 能有 95% 的可能性使每箱中至少有 100 个合格产品.

第七题

问题

在赌场开始玩轮盘赌之前, 你需要寻找一些可以利用的技巧. 因此, 你可以旁观 100 轮, 每轮结果均为 1 到 36 之间的整数, 并计算结果为奇数的轮数. 如果计数超过 55, 你就会认为轮盘赌不公平. 假设轮盘赌是公平的, 请求出你会做出错误决定的概率的近似值.

解答

设 S 是结果为奇数的次数，这是一个二项式随机变量，参数 $n = 100, p = 0.5$ ，因此 $\mathbf{E}[X] = 100 \cdot 0.5 = 50$ 和 $\sigma_S = \sqrt{100 \cdot 0.5 \cdot 0.5} = \sqrt{25} = 5$ 。根据二项式的常量近似可知

$$\mathbf{P}(S > 55) = \mathbf{P}\left(\frac{S - 50}{5} > \frac{55 - 50}{5}\right) \approx 1 - \Phi(1) = 1 - 0.8413 = 0.1587.$$

使用 de Moivre-Laplace 近似可以获得更好的近似值，该近似值为

$$\begin{aligned}\mathbf{P}(S > 55) &= \mathbf{P}(S \geq 55.5) = \mathbf{P}\left(\frac{S - 50}{5} > \frac{55.5 - 50}{5}\right) \\ &\approx 1 - \Phi(1.1) = 1 - 0.8643 = 0.1357\end{aligned}$$

第 11 周习题

统计量部分

第一题

问题

设 x_1, x_2, x_n 和 $y_1, y_2, \dots, y_n$ 是两组样本观测值, 且关系如下:

$$y_i = ax_i + b, i = 1, 2, \dots, n$$

其中, a 和 b 为非零常数. 试求:

1. 样本均值 $\bar{x}$ 和 $\bar{y}$ 间的关系;
2. 样本方差 s_x^2 和 s_y^2 间的关系.

解答

(1)

$$\bar{y} = \frac{1}{n} \sum_{i=1}^n y_i = \frac{1}{n} \sum_{i=1}^n (ax_i + b) = a\bar{x} + b$$

(2)

$$\begin{aligned} s_y^2 &= \frac{1}{n-1} \sum_{i=1}^n (y_i - \bar{y})^2 \\ &= \frac{1}{n-1} \sum_{i=1}^n (ax_i + b - a\bar{x} - b)^2 \\ &= a^2 s_x^2 \end{aligned}$$

第二题

问题

设总体 X 的 3 阶矩存在, 若 $x_1, x_2, \dots, x_n$ 是取自该总体的简单随机样本, $\bar{x}$ 为样本均值, s^2 为样本方差, 试证:

$$\text{Cov}(\bar{x}, s^2) = \frac{\nu_3}{n},$$

其中 $\nu_3 = E(x - E(x))^3$.

解答

$$\begin{aligned} Cov(\bar{x}, s^2) &= E[(\bar{x} - E(\bar{x}))(s^2 - E(s^2))] \\ &= E[(\bar{x} - \mu)(s^2 - \sigma^2)] \\ &= E[(\bar{x} - \mu)s^2] - E[(\bar{x} - \mu)\sigma^2] \\ &= E[(\bar{x} - \mu)s^2] \\ (\bar{x} - \mu)s^2 &= \frac{1}{n-1}(\bar{x} - \mu) \sum_{i=1}^n (x_i - \bar{x})^2 \\ &= \frac{1}{n-1}(\bar{x} - \mu) \sum_{i=1}^n ((x_i - \mu) - (\bar{x} - \mu))^2 \\ &= \frac{1}{n-1}[(\bar{x} - \mu) \sum_{i=1}^n (x_i - \mu)^2 - n(\bar{x} - \mu)^3] \\ E[(\bar{x} - \mu)(x_i - \mu)^2] &= \frac{1}{n}E[\sum_{i=1}^n (x_i - \mu)(x_i - \mu)^2] \\ &= \frac{1}{n}E[(x_i - \mu)^3 + \sum_{i \neq j} (x_j - \mu)(x_i - \mu)^2] \\ &= \frac{v_3}{n} \\ E[(\bar{x} - \mu)^3] &= \frac{1}{n^3}E[\sum_{i=1}^n (x_i - \mu)]^3 \\ &= \frac{1}{n^3}[E\sum_{i=1}^n (x_i - \mu)^3 + 0] \\ &= \frac{v_3}{n^2} \\ Cov(\bar{x}, s^2) &= E[(\bar{x} - \mu)s^2] = \frac{1}{n-1}(v_3 - \frac{v_3}{n}) = \frac{v_3}{n} \end{aligned}$$

第三题

问题

设 $\bar{x}_1$ 和 $\bar{x}_2$ 是从同一正态总体 $N(\mu, \sigma^2)$ 独立抽取的容量相同的两个样本均值. 试确定样本容量 n , 使得两样本均值的差超过 σ 的概率不超过 0.01.

解答

由于 $\bar{x}_i \sim N(\mu, \frac{\sigma^2}{n})$, $i = 1, 2$ 且相互独立, 所以, $\bar{x}_2 - \bar{x}_1 \sim N(0, \frac{2\sigma^2}{n})$.

$$P(|\bar{x}_2 - \bar{x}_1| > \sigma) = P(\frac{|\bar{x}_2 - \bar{x}_1|}{\sqrt{2\sigma^2/n}} > \sigma) = 2[1 - \Phi(\sqrt{\frac{n}{2}})] \leq 0.01$$

因此,

$$\Phi\left(\sqrt{\frac{n}{2}}\right) \geq 0.995$$

$$n \geq 2.575^2 * 2 = 13.26$$

只要样本容量 $n \geq 14$, 则可使同一正态总体的两样本均值的差超过标准差的可能性不大于 0.01.

第四题

问题

从指数总体 $Exp(1/\theta)$ 抽取了 40 个样品, 试求 $\bar{x}$ 的渐近分布。

解答

由于指数总体 $Exp(\frac{1}{\theta})$ 的均值为 θ , 方差为 θ^2 , 则 $\bar{x}$ 的渐近分布为 $N(\theta, \frac{\theta^2}{40})$.

第五题

问题

设总体 X 的分布函数 $F(x)$ 是连续的, $x_{(1)}, x_{(2)}, \dots, x_{(n)}$ 为取自此总体的次序统计量, 设 $\eta_i = F(x_{(i)})$, 试证:

1. $\eta_1 \leq \eta_2 \leq \dots \leq \eta_n$, η_i 是来自均匀分布 $U(0, 1)$ 总体的次序统计量;
2. $E(\eta_i) = \frac{i}{n+1}$, $\text{Var}(\eta_i) = \frac{i(n+1-i)}{(n+1)^2(n+2)}$, $1 \leq i \leq n$;
3. η_i 和 η_j 的协方差矩阵为

$$\begin{pmatrix} \frac{a_1(1-a_1)}{n+2} & \frac{a_1(1-a_2)}{n+2} \\ \frac{a_1(1-a_2)}{n+2} & \frac{a_2(1-a_2)}{n+2} \end{pmatrix}$$

其中, $a_1 = \frac{i}{n+1}$, $a_2 = \frac{j}{n+1}$.

解答

(1) 由于分布函数 $F(x)$ 是递增的, 所以, $\eta_1 \leq \eta_2 \leq \dots \leq \eta_n$ 成立; 又因为分布函数 $F(x)$ 具有连续性, 且 $F(x)$ 服从均匀分布 $U(0, 1)$, 所以, η_i 是来自均匀分布 $U(0, 1)$ 总体的次序统计量。(2) 由于 η_i 是来自均匀分布 $U(0, 1)$ 总体的次序统计量, 即 $\eta_i \sim Be(i, n-i+1)$. 即

$$E(\eta_i) = \frac{i}{n+1}$$

$$Var(\eta_i) = \frac{i(n+1-i)}{(n+1)^2(n+2)}$$

其中, $1 \leq i \leq n$. (3) η_i 和 η_j 的联合分布密度为:

$$p_{ij}(y, z) = \frac{n!}{(i-1)!(j-i-1)!(n-j)!} y^{i-1} (z-y)^{j-i-1} (1-z)^{n-j}$$

其中, $y \leq z$.

$$\begin{aligned} E(\eta_i, \eta_j) &= \int_0^1 \int_0^x yz p_{ij}(y, z) dy dz \\ &= \int_0^1 \int_0^x yz \frac{n!}{(i-1)!(j-i-1)!(n-j)!} y^{i-1} (z-y)^{j-i-1} (1-z)^{n-j} dy dz \\ &= \frac{n!}{(i-1)!(j-i-1)!(n-j)!} \int_0^1 (1-z)^{n-j} z^{j-i} \int_0^x y^i (1-\frac{y}{z})^{j-i-1} dy dz \\ &= \frac{n!}{(i-1)!(j-i-1)!(n-j)!} \int_0^1 (1-z)^{n-j} z^{j+1} dz \int_0^1 t^i (1-t)^{j-i-1} dt \\ &= \frac{n!}{(i-1)!(j-i-1)!(n-j)!} \frac{\Gamma(j+2)\Gamma(n-j+1)}{\Gamma(n+3)} \frac{\Gamma(i+1)\Gamma(j-i)}{\Gamma(j+1)} \\ &= \frac{ij+i}{(n+1)(n+2)} \\ Cov(\eta_i, \eta_j) &= E(\eta_i, \eta_j) - E(\eta_i)E(\eta_j) \\ &= \frac{ij+i}{(n+1)(n+2)} - \frac{ij}{(n+1)^2} \\ &= \frac{-ij+(n+1)i}{(n+1)^2(n+2)} \end{aligned}$$

所以, η_i 和 η_j 的协方差矩阵为:

$$\begin{aligned} &\begin{pmatrix} Cov(\eta_i, \eta_i) & Cov(\eta_i, \eta_j) \\ Cov(\eta_j, \eta_i) & Cov(\eta_j, \eta_j) \end{pmatrix} \\ &= \begin{pmatrix} \frac{a_1(1-a_1)}{n+2} & \frac{a_1(1-a_2)}{n+2} \\ \frac{a_1(1-a_2)}{n+2} & \frac{a_2(1-a_2)}{n+2} \end{pmatrix} \end{aligned}$$

其中,

$$a_1 = \frac{i}{n+1}, a_2 = \frac{j}{n+1}.$$

第 12 周习题

抽样分布部分

第一题

问题

$x_1, x_2, \dots, x_n$ 是来自 $N(\mu, 1)$ 的样本, 试确定最小的常数 c 使得对任意的 $\mu \geq 0$ 有 $P(|\bar{x}| < c) \leq \alpha$.

解答

由于 $\bar{x} \sim N(\mu, \frac{1}{n})$, 所以 $P(\bar{x} < c)$ 的值依赖于 μ , 它是 μ 的函数记为 $g(\mu)$, 于是

$$g(\mu) = P_\mu(|\bar{x}| < c) = P(-c < \bar{x} < c) = \Phi(\sqrt{n}(c - \mu)) - \Phi(-\sqrt{n}(c + \mu))$$

其导函数为

$$g(\mu)' = -\sqrt{n}[\varphi(\sqrt{n}(c - \mu)) - \varphi(-\sqrt{n}(c + \mu))]$$

由于 $g(\mu)' \leq 0$, $g(\mu)$ 为减函数, 并在 $\mu = 0$ 处取最大值

故只需 $2\Phi(\sqrt{nc}) - 1 \leq \alpha$

第二题

问题

设随机变量 $X \sim F(n, m)$, 证明:

$$Z = \frac{\frac{n}{m}X}{(1 + \frac{n}{m}X)}$$

服从贝塔分布, 并指出其参数.

解答

若 $X \sim F(n, m)$, 则 X 的密度函数为:

$$p_X(x) = \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{n}{2})\Gamma(\frac{m}{2})} \left(\frac{n}{m}\right)^{\frac{n}{2}} x^{\frac{n}{2}-1} \left(1 + \frac{n}{m}x\right)^{-\frac{m+n}{2}}$$

因为 $Z = \frac{\frac{n}{m}X}{1 + \frac{n}{m}X}$ 在 $(0, +\infty)$ 上严格单调增函数, 其反函数为 $x = \frac{mz}{n(1-z)}$.

所以, Z 的密度函数为:

$$\begin{aligned} p_Z(z) &= \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{n}{2})\Gamma(\frac{m}{2})} \left(\frac{n}{m}\right)^{\frac{n}{2}} \left(\frac{mz}{n(1-z)}\right)^{\frac{n}{2}-1} \left(1 + \frac{z}{1-z}\right)^{-\frac{m+n}{2}} \frac{m}{n(1-z)^2} \\ &= \frac{\Gamma(\frac{m+n}{2})}{\Gamma(\frac{n}{2})\Gamma(\frac{m}{2})} z^{\frac{n}{2}-1} (1-z)^{\frac{m}{2}-1} \end{aligned}$$

其中, $0 < z < 1$. 说明 Z 服从 $Be(\frac{n}{2}, \frac{m}{2})$, 其两个参数分别为 F 分布两个自由度的一半.

第三题

问题

设 $x_1, x_2, \dots, x_n$ 是来自 $N(\mu_1, \sigma^2)$ 的样本, $y_1, y_2, \dots, y_m$ 是来自 $N(\mu_2, \sigma^2)$ 的样本, c, d 是任意两个不为 0 的常数, 证明

$$t = \frac{c(\bar{x} - \mu_1) + d(\bar{y} - \mu_2)}{s_w \sqrt{\frac{c^2}{n} + \frac{d^2}{m}}} \sim t(n+m-2)$$

其中 $s_w^2 = \frac{(n-1)s_x^2 + (m-1)s_y^2}{n+m-2}$.

解答

可得:

$$\begin{aligned} c(\bar{x} - \mu_1) &\sim N(0, \frac{c^2 \sigma^2}{n}), d(\bar{y} - \mu_2) \sim N(0, \frac{d^2 \sigma^2}{m}), \\ \frac{(n-1)s_x^2}{\sigma^2} &\sim \chi^2(n-1), \frac{(m-1)s_y^2}{\sigma^2} \sim \chi^2(m-1), \end{aligned}$$

且 $\bar{x}, \bar{y}, s_x^2, s_y^2$ 相互独立, 可得:

$$c(\bar{x} - \mu_1) + d(\bar{y} - \mu_2) \sim N(0, \frac{c^2 \sigma^2}{n} + \frac{d^2 \sigma^2}{m}).$$

$$\frac{(n+m-2)s_w^2}{\sigma^2} = \frac{(n-1)s_x^2}{\sigma^2} + \frac{(m-1)s_y^2}{\sigma^2} \sim \chi^2(n+m-2).$$

即:

$$\begin{aligned} t &= \frac{c(\bar{x} - \mu_1) + d(\bar{y} - \mu_2)}{s_w \sqrt{\frac{c^2}{n} + \frac{d^2}{m}}} \\ &= \frac{\left[c(\bar{x} - \mu_1) + d(\bar{y} - \mu_2) \right] / \sqrt{\frac{c^2}{n} + \frac{d^2}{m}}}{\sqrt{\frac{(n+m-2)s_w^2}{\sigma^2} / (n+m-2)}} \\ &\sim t(n+m-2) \end{aligned}$$

充分统计量部分

第四题

问题

设 $x_1, x_2, \dots, x_n$ 是来自几何分布

$$P(X = x) = \theta(1 - \theta)^x$$

的样本, 证明 $T = \sum_{i=1}^n x_i$ 是充分统计量.

解答

$$p(T = t) = \binom{n+t-1}{t} \theta^n (1 - \theta)^t, t = 0, 1, 2, \dots$$

当给定 $T = t$ 时, $\sum_{i=1}^n x_i = t$.

$$\begin{aligned} P(x_1, x_2, \dots, x_n | T = t) &= \frac{P(x_1, x_2, \dots, x_{n-1}, t - \sum_{i=1}^{n-1} x_i)}{P(T = t)} \\ &= \frac{\prod_{i=1}^{n-1} P(x_i) P(t - \sum_{i=1}^{n-1} x_i)}{\binom{n+t-1}{t} \theta^n (1 - \theta)^t} \\ &= \frac{\prod_{i=1}^{n-1} \left(\theta(1 - \theta)^{x_i} \right) \theta(1 - \theta)^{t - \sum_{i=1}^{n-1} x_i}}{\binom{n+t-1}{t} \theta^n (1 - \theta)^t} \\ &= \frac{\theta^n (1 - \theta)^t}{\binom{n+t-1}{t} \theta^n (1 - \theta)^t} \\ &= \frac{1}{\binom{n+t-1}{t}} \end{aligned}$$

该条件分布与 θ 无关, 因而 $T = \sum_{i=1}^n x_i$ 是充分统计量. (采用定义法或因子分解定理均可.)

第五题

问题

设 $x_1, x_2, \dots, x_n$ 来自均匀分布 $U(\theta_1, \theta_2)$ 的样本, 试给出充分统计量.

解答

总体的密度函数为:

$$p(x; \theta_1, \theta_2) = \begin{cases} \frac{1}{\theta_2 - \theta_1}, & \theta_1 < x < \theta_2 \\ 0, & \text{others} \end{cases}$$

样本的联合密度函数为:

$$p(x_1, x_2, \dots, x_n; \theta_1, \theta_2) = \begin{cases} \left(\frac{1}{\theta_2 - \theta_1}\right)^n, & \theta_1 < x_{(1)} < x_{(2)} < \theta_2 \\ 0, & \text{others} \end{cases}$$

即可以写成:

$$p(x_1, x_2, \dots, x_n; \theta_1, \theta_2) = \left(\frac{1}{\theta_2 - \theta_1}\right)^n I_{\theta_1 < x_{(1)} < x_{(2)} < \theta_2}$$

令 $t_1 = x_{(1)}, t_2 = x_{(n)}$,

$$p(x_1, x_2, \dots, x_n; \theta_1, \theta_2) = g(t; \theta_1, \theta_2)h(x)$$

$$h(x) = 1$$

$$g(t; \theta_1, \theta_2) = \left(\frac{1}{\theta_2 - \theta_1}\right)^n I_{\theta_1 < x_{(1)} < x_{(2)} < \theta_2}$$

由因子分解定理得, $T = (x_{(1)}, x_{(n)})$ 是参数 (θ_1, θ_2) 的充分统计量.

第六题

问题

设 $x_1, x_2, \dots, x_n$ 是来自正态总体 $N(\mu, \sigma_1^2)$ 的样本, $y_1, y_2, \dots, y_m$ 是来自于另一正态总体 $N(\mu, \sigma_2^2)$ 的样本, 这两个样本相互独立, 试给出 $(\mu, \sigma_1^2, \sigma_2^2)$ 的充分统计量.

解答

样本 $x_1, x_2, \dots, x_n, y_1, y_2, \dots, y_m$ 的联合密度函数为:

$$\begin{aligned} & p(x_1, x_2, \dots, x_n, y_1, y_2, \dots, y_m) \\ &= \prod_{i=1}^n \left(\frac{1}{\sqrt{2\pi\sigma_1^2}} e^{-\frac{(x_i - \mu)^2}{2\sigma_1^2}} \right) \prod_{i=1}^m \left(\frac{1}{\sqrt{2\pi\sigma_2^2}} e^{-\frac{(y_i - \mu)^2}{2\sigma_2^2}} \right) \\ &= (2\pi)^{-\frac{m+n}{2}} \sigma_1^{-n} \sigma_2^{-m} e^{-\left(\frac{1}{2\sigma_1^2} \sum_{i=1}^n x_i^2 + \frac{1}{2\sigma_2^2} \sum_{i=1}^m y_i^2 - \left(\frac{n\bar{x}}{\sigma_1^2} + \frac{m\bar{y}}{\sigma_2^2}\right)\mu + \left(\frac{n}{2\sigma_1^2} + \frac{m}{2\sigma_2^2}\right)\mu^2\right)} \end{aligned}$$

其中, $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i, \bar{y} = \frac{1}{m} \sum_{i=1}^m y_i$.

令 $t = (t_1, t_2, t_3, t_4) = (\bar{x}, \bar{y}, \sum_{i=1}^n x_i^2, \sum_{i=1}^m y_i^2)$, 取:

$$h(x_1, x_2, \dots, x_n, y_1, y_2, \dots, y_m) = 1$$

$$g(t; \mu, \sigma_1, \sigma_2) = (2\pi)^{-\frac{m+n}{2}} \sigma_1^{-n} \sigma_2^{-m} e^{-\left(\frac{1}{2\sigma_1^2} t_3 + \frac{1}{2\sigma_2^2} t_4 - \left(\frac{nt_1}{\sigma_1^2} + \frac{mt_2}{\sigma_2^2}\right)\mu + \left(\frac{n}{2\sigma_1^2} + \frac{m}{2\sigma_2^2}\right)\mu^2\right)}$$

由因子分解定理得, $t = (t_1, t_2, t_3, t_4) = (\bar{x}, \bar{y}, \sum_{i=1}^n x_i^2, \sum_{i=1}^m y_i^2)$ 是 $(\mu, \sigma_1^2, \sigma_2^2)$ 的充分统计量。

第 13 周习题

参数估计部分

第一题

问题

设总体分布列/密度函数如下, $x_1, x_2, \dots, x_n$ 是样本, 试求未知参数的矩估计:

1. $P(X = x) = (x - 1)\theta^2(1 - \theta)^{x-2}, x = 2, 3, \dots, 0 < \theta < 1.$
2. $p(x; \theta) = (\theta + 1)x^\theta, 0 < x < 1, \theta > 0.$

解答

(1)

$$\begin{aligned} E(X) &= \sum_{x=2}^{+\infty} x(x-1)\theta^2(1-\theta)^{x-2} \\ &= \theta^2 \sum_{x=2}^{+\infty} x(x-1)(1-\theta)^{x-2} \\ &= \theta^2 \cdot \frac{2}{\theta^3} \\ &= \frac{2}{\theta}. \end{aligned}$$

即 $\theta = \frac{2}{E(X)}$, 所以 θ 的矩估计为 $\hat{\theta} = \frac{2}{\bar{x}}$.

(2)

$$\begin{aligned} E(X) &= \int_0^1 x(\theta + 1)x^\theta dx \\ &= \frac{\theta + 1}{\theta + 2}. \end{aligned}$$

即 $\theta = \frac{1-2E(X)}{E(X)-1}$, 所以 θ 的矩估计为 $\hat{\theta} = \frac{1-2\bar{x}}{\bar{x}-1}$.

第二题

问题

设总体为 $N(\mu, 1)$, 现对该总体观测 n 次, 发现有 k 次观测值为正, 使用频率替换方法求 μ 的估计。

解答

观测值为正的频率是 $f = \frac{k}{n}$, 接下来将计算观测值为正的概率: 因为总体 $X \sim N(\mu, 1)$, 所以, $P(X > 0) = 1 - P(X < 0) = 1 - P(X - \mu < -\mu) = 1 - \Phi(-\mu) = \Phi(\mu)$. 利用频率替换概率的想法, 有 $\Phi(\hat{\mu}) = \frac{k}{n}$, 所以, μ 的矩估计为: $\hat{\mu} = \Phi^{-1}(\frac{k}{n})$.

第三题

问题

设总体的概率密度函数如下, $x_1, x_2, \dots, x_n$ 是样本, 试求未知参数的最大似然估计:

1. $p(x; \theta) = \frac{1}{2\theta} e^{-|x|/\theta}, \theta > 0;$
2. $p(x; \theta_1, \theta_2) = \frac{1}{\theta_2 - \theta_1}, \theta_1 < x < \theta_2;$

解答

(1) 似然函数为:

$$L(\theta) = \left(\frac{1}{2\theta}\right)^n e^{-\frac{\sum_{i=1}^n |x_i|}{\theta}}.$$

对数似然函数为:

$$\ln L(\theta) = -n \ln 2\theta - \frac{\sum_{i=1}^n |x_i|}{\theta}.$$

关于 θ 求导:

$$\begin{aligned} \frac{\partial \ln L(\theta)}{\partial \theta} &= \frac{-n}{\theta} + \frac{\sum_{i=1}^n |x_i|}{\theta^2} = 0. \\ \hat{\theta} &= \frac{\sum_{i=1}^n |x_i|}{n}. \end{aligned}$$

并且,

$$\frac{\partial^2 \ln L(\theta)}{\partial \theta^2} \Big|_{\hat{\theta}} = -\frac{n^3}{(\sum_{i=1}^n |x_i|)^2} < 0.$$

所以, $\hat{\theta}$ 是 θ 的最大似然估计。

(2) 似然函数为:

$$L(\theta) = \frac{1}{(\theta_2 - \theta_1)^n} I_{\theta_1 < x_{(1)} < x_{(n)} < \theta_2}.$$

由于, 要使 $L(\theta)$ 尽量大, 首先, 示性函数的取值应为 1, 即 $\theta_1 < x_{(1)} < x_{(n)} < \theta_2$; 其次, 要使 $\theta_2 - \theta_1$ 要尽量小, 所以, θ_1 的最大似然估计为 $x_{(1)}$, θ_2 的最大似然估

计为 $x_{(n)}$ 。

第四题

问题

众所周知，双胞胎可分为同卵双胞胎与异卵双胞胎。在一项针对双胞胎的研究中，研究者关心的是一对双胞胎是同卵双胞胎的概率，记为 p ，而且研究者也关心一个孩子是男孩的概率，记为 q 。在这项研究中，研究者招募到了 n 对双胞胎（包括龙凤胎），其中 n_1 是两个男孩的双胞胎， n_2 是两个女孩的双胞胎， $n_3 = n - (n_1 + n_2)$ 是龙凤胎（一个男孩一个女孩）。另外，研究者虽然知道不同性别的双胞胎一定不是同卵双胞胎，但并不知道其中哪些相同性别的双胞胎为同卵双胞胎。

1. 采用 EM 算法，写出 $\theta = (p, q)$ 的最大似然估计的形式。（提示：构造合适的潜变量，定义似然函数，写出 EM 算法中的 E 步和 M 步）
2. (编程题) 在 $n = 1000, n_1 = 432, n_2 = 232, n_3 = 336$ 时，编程计算出 θ 的最大似然估计。

解答

(1) 令 MM 代表双胞胎均是男孩子，FF 代表双胞胎均是女孩子，MF 代表龙凤胎，其中，龙凤胎一定是异卵双胞胎，但是性别相同的双胞胎可能为同卵或异卵双胞胎。

因此，我们可得： $P(MM) = pq + (1-p)q^2$ ， $P(FF) = p(1-q) + (1-p)(1-q)^2$ ， $P(MF) = 2(1-p)(1-q)q$ 。

令 $\mathbf{x} = (n_1, n_2, n_3)$ 为可观测变量，设 $\mathbf{z} = (n_{11}, n_{12}, n_{21}, n_{22}, n_3)$ ，其中 n_{11} 是双胞胎均为男孩并来自同卵双胞胎的人数， $n_{12} = n_1 - n_{11}$ 是双胞胎均为男孩并来自异卵双胞胎的人数，同理， n_{21} 是双胞胎均为女孩并来自同卵双胞胎的人数， $n_{22} = n_2 - n_{21}$ 是双胞胎均为女孩并来自异卵双胞胎的人数。

关于参数 $\theta = (p, q)$ 的似然函数：

$$\begin{aligned} L(\theta, \mathbf{z}) &\propto (pq)^{n_{11}} ((1-p)q^2)^{n_{12}} (p(1-q))^{n_{21}} ((1-p)(1-q)^2)^{n_{22}} (2(1-p)(1-q)q)^{n_3} \\ &\propto p^{n_{11}+n_{21}} (1-p)^{n_{12}+n_{22}+n_3} q^{n_{11}+2n_{12}+n_3} (1-q)^{n_{21}+2n_{22}+n_3}. \end{aligned}$$

对数似然函数为:

$$\begin{aligned} \ln L(\theta, \mathbf{z}) &\propto (n_{11} + n_{21}) \ln p + (n_{12} + n_{22} + n_3) \ln(1-p) \\ &\quad + (n_{11} + 2n_{12} + n_3) \ln q + (n_{21} + 2n_{22} + n_3) \ln(1-q). \end{aligned}$$

已知 $\mathbf{x} = (n_1, n_2, n_3)$ 和 $\theta = (p, q)$, 可得:

$$\begin{aligned} n_{11} &\sim b(n_1, \frac{pq}{pq + (1-p)q^2}). \\ n_{21} &\sim b(n_2, \frac{p(1-q)}{p(1-q) + (1-p)(1-q)^2}). \end{aligned}$$

E 步:

$$\begin{aligned} Q(\theta|\mathbf{x}, \theta^{(k)}) &= E_{\mathbf{z}} \ln L(\theta, \mathbf{z}) \\ &\propto (n_{11}^{(k)} + n_{21}^{(k)}) \ln p + (n_{12}^{(k)} + n_{22}^{(k)} + n_3) \ln(1-p) \\ &\quad + (n_{11}^{(k)} + 2n_{12}^{(k)} + n_3) \ln q + (n_{21}^{(k)} + 2n_{22}^{(k)} + n_3) \ln(1-q). \end{aligned}$$

其中,

$$\begin{aligned} n_{11}^{(k)} &= E(n_{11}|\mathbf{x}, \theta^{(k)}) = n_1 \frac{p^{(k)}q^{(k)}}{p^{(k)}q^{(k)} + (1-p^{(k)})q^{(k)^2}}. \\ n_{12}^{(k)} &= n_1 - n_{11}^{(k)} = n_1 \frac{(1-p^{(k)})q^{(k)^2}}{p^{(k)}q^{(k)} + (1-p^{(k)})q^{(k)^2}}. \\ n_{21}^{(k)} &= E(n_{21}|\mathbf{x}, \theta^{(k)}) = n_2 \frac{p^{(k)}(1-q^{(k)})}{p^{(k)}(1-q^{(k)}) + (1-p^{(k)})(1-q^{(k)})^2}. \\ n_{22}^{(k)} &= n_2 - n_{21}^{(k)} = n_2 \frac{(1-p^{(k)})(1-q^{(k)})^2}{p^{(k)}(1-q^{(k)}) + (1-p^{(k)})(1-q^{(k)})^2}. \end{aligned}$$

M 步:

$$\begin{aligned} p^{(k+1)} &= \frac{n_{11}^{(k)} + n_{21}^{(k)}}{n_{11}^{(k)} + n_{12}^{(k)} + n_{21}^{(k)} + n_{22}^{(k)} + n_3} = \frac{n_{11}^{(k)} + n_{21}^{(k)}}{n}. \\ q^{(k+1)} &= \frac{n_{11}^{(k)} + 2n_{12}^{(k)} + n_3}{n_{11}^{(k)} + 2n_{12}^{(k)} + n_3 + n_{21}^{(k)} + 2n_{22}^{(k)} + n_3} = \frac{n_{11}^{(k)} + 2n_{12}^{(k)} + n_3}{n + n_{12}^{(k)} + n_{22}^{(k)} + n_3}. \end{aligned}$$

(2) 当 $n = 1000$, $n_1 = 432$, $n_2 = 232$, $n_3 = 336$ 时, $p=0.3$, $q=0.6$.

第 15 周习题

点估计的评价方法部分

第一题

问题

设 $\hat{\theta}$ 是参数 θ 的无偏估计, 且有 $\text{Var}(\hat{\theta}) > 0$, 试证 $(\hat{\theta})^2$ 不是 θ^2 的无偏估计。

解答

由方差的定义可知:

$$\text{Var}(\hat{\theta}) = E(\hat{\theta}^2) - E^2(\hat{\theta}) > 0.$$

且 $\hat{\theta}$ 是参数 θ 的无偏估计, 即 $E(\hat{\theta}) = \theta$. 可得:

$$E(\hat{\theta}^2) = E^2(\hat{\theta}) + \text{Var}(\hat{\theta}) = \theta^2 + \text{Var}(\hat{\theta}) > \theta^2.$$

所以, $(\hat{\theta})^2$ 不是 θ^2 的无偏估计。

第二题

问题

设 $x_1, x_2, \dots, x_n$ 是来自于下列总体的简单样本

$$p(x; \theta) = \begin{cases} 1, \theta - \frac{1}{2} \leq x \leq \theta + \frac{1}{2}, & -\infty < \theta < \infty \\ 0, & \text{其他}, \end{cases}$$

证明样本均值 $\bar{x}$ 及 $\frac{1}{2}(x_{(1)} + x_{(n)})$ 都是 θ 的无偏估计, 问哪一个更为有效?

解答

由题意可知: $X \sim U(\theta - \frac{1}{2}, \theta + \frac{1}{2})$, $E(X) = \theta$, $\text{Var}(X) = \frac{1}{12}$.

可得 $E(\bar{x}) = \theta$, 所以样本均值 $\bar{x}$ 是 θ 的无偏估计, 且 $\text{Var}(\bar{x}) = \frac{1}{12n}$.

接下来计算 $\frac{1}{2}(x_{(1)} + x_{(n)})$ 的均值和方差:

令 $Y = X - (\theta - \frac{1}{2}) \sim U(0, 1)$,

即: $y_i = x_i - (\theta - \frac{1}{2})$, $i = 1, 2, \dots, n$.

则:

$$\frac{1}{2}(x_{(1)} + x_{(n)}) = \frac{1}{2}(y_{(1)} + y_{(n)}) + \theta - \frac{1}{2}$$

又因为 $y_{(i)} \sim Be(i, n-i+1)$, 所以, $E(y_{(1)}) = \frac{1}{n+1}$, $E(y_{(n)}) = \frac{n}{n+1}$.

可得:

$$E(\frac{1}{2}(x_{(1)} + x_{(n)})) = \frac{1}{2}E(y_{(1)} + y_{(n)}) + \theta - \frac{1}{2} = \theta.$$

所以 $\frac{1}{2}(x_{(1)} + x_{(n)})$ 是 θ 的无偏估计。

又因为 $y_{(n)} - y_{(1)} \sim Be(n-1, 2)$, 可得:

$$\begin{aligned} Var(y_{(1)}) &= Var(y_{(n)}) = \frac{n}{(n+1)^2(n+2)}. \\ Var(y_{(n)} - y_{(1)}) &= \frac{2(n-1)}{(n+1)^2(n+2)}. \\ Cov(y_{(1)}, y_{(n)}) &= \frac{1}{2} \left(Var(y_{(1)}) + Var(y_{(n)}) - Var(y_{(n)} - y_{(1)}) \right) \\ &= \frac{1}{(n+1)^2(n+2)}. \end{aligned}$$

于是,

$$\begin{aligned} Var\left(\frac{1}{2}(x_{(1)} + x_{(n)})\right) &= \frac{1}{4} \left(Var(y_{(1)}) + Var(y_{(n)}) + 2Cov(y_{(1)}, y_{(n)}) \right) \\ &= \frac{1}{4} \left(\frac{2n}{(n+1)^2(n+2)} + \frac{2}{(n+1)^2(n+2)} \right) \\ &= \frac{1}{2(n+1)(n+2)}. \end{aligned}$$

当 $n > 2$ 时, 有 $\frac{1}{12n} > \frac{1}{2(n+1)(n+2)}$. 说明在此情况下, $\frac{1}{2}(x_{(1)} + x_{(n)})$ 比 $\bar{x}$ 更有效。

第三题

问题

设从均值为 μ , 方差为 $\sigma^2 > 0$ 的总体中分布抽取容量为 n_1 和 n_2 的两独立样本, $\bar{x}_1$ 和 $\bar{x}_2$ 是这两个样本的均值。试证, 对于任意常数 $a, b(a+b=1)$, $Y = a\bar{x}_1 + b\bar{x}_2$ 都是 μ 的无偏估计, 并确定常数 a, b 使得 $Var(Y)$ 达到最小。

解答

由于 $\bar{x}_1$ 和 $\bar{x}_2$ 分别为样本量 n_1 和 n_2 对应的均值,

则: $E(\bar{x}_1) = \mu$, $E(\bar{x}_2) = \mu$, $Var(\bar{x}_1) = \frac{\sigma^2}{n_1}$, $Var(\bar{x}_2) = \frac{\sigma^2}{n_2}$.

所以,

$$\begin{aligned} E(Y) &= E(a\bar{x}_1 + b\bar{x}_2) \\ &= aE(\bar{x}_1) + bE(\bar{x}_2) \\ &= (a+b)\mu \\ &= \mu. \end{aligned}$$

即 Y 是 μ 的无偏估计。

由于 $a+b=1$, Y 又可写成: $Y = a\bar{x}_1 + (1-a)\bar{x}_2$.

$$\begin{aligned} Var(Y) &= \frac{a^2\sigma^2}{n_1} + \frac{(1-a)^2\sigma^2}{n_2} \\ &= \sigma^2 \left(\left(\frac{1}{n_1} + \frac{1}{n_2} \right) a^2 + \frac{1-2a}{n_2} \right). \end{aligned}$$

对其求导, 当 $a = \frac{n_1}{n_1+n_2}$ 时, $Var(Y)$ 可达到最小值, 此时 $b = \frac{n_2}{n_1+n_2}$.

第四题

问题

设总体密度函数为 $p(x; \theta) = \theta x^{\theta-1}$, $0 < x < 1, \theta > 0$, $x_1, x_2, \dots, x_n$ 是样本. 求 $g(\theta) = 1/\theta$ 的最大似然估计.

解答

$$\begin{aligned} L(\theta) &= \prod_{i=1}^n \theta x_i^{\theta-1}. \\ \ln L(\theta) &= n \ln \theta + (\theta - 1) \sum_{i=1}^n \ln x_i \\ &= -n \ln g(\theta) + \left(\frac{1}{g(\theta)} - 1 \right) \sum_{i=1}^n \ln x_i. \\ \frac{\partial \ln L(\theta)}{\partial g(\theta)} &= -\frac{\theta}{g(\theta)} - \frac{1}{g^2(\theta)} \sum_{i=1}^n \ln x_i = 0. \\ \hat{g}(\theta) &= -\frac{1}{n} \sum_{i=1}^n \ln x_i. \end{aligned}$$

(此题也可以先求关于 θ 的 MLE, 再代入到 $g(\theta)$ 函数里)

第五题

问题

设总体 $X \sim \text{Exp}(1/\theta)$, $x_1, x_2, \dots, x_n$ 是样本。

1. 验证 θ 的矩估计和最大似然估计都是 $\bar{x}$;
2. 验证 $\bar{x}$ 也是 θ 的相合估计和无偏估计;
3. 试证明在均方误差准则下存在优于 $\bar{x}$ 的估计。(提示: 考虑 $\hat{\theta}_n = a\bar{x}$, 找均方误差最小者)

解答

(a)

因为 $X \sim \text{Exp}(1/\theta)$, $f(x) = \frac{1}{\theta} e^{-\frac{x}{\theta}}$.

$E(X) = \theta = \bar{x}$, 所以 θ 的矩估计为 $\bar{x}$;

$\ln L(\theta) = -n \ln \theta - \frac{1}{\theta} \sum_{i=1}^n x_i$, 令 $\frac{\partial \ln L(\theta)}{\partial \theta} = 0$, 得 $\hat{\theta} = \frac{1}{n} \sum_{i=1}^n x_i = \bar{x}$, 所以 θ 的 MLE 为 $\bar{x}$ 。

(b)

因为 $E(\bar{x}) = \frac{1}{n} \sum_{i=1}^n E(x_i) = \theta$, 所以 $\bar{x}$ 也是 θ 的无偏估计;

$\text{Var}(\bar{x}) = \frac{1}{n^2} \sum_{i=1}^n \text{Var}(x_i) = \frac{\theta^2}{n}$, 当 n 趋向于正无穷时, $\text{Var}(\bar{x})$ 趋向于 0, 所以 $\bar{x}$ 也是 θ 的相合估计。

(c)

令 $\hat{\theta}_a = a\bar{x}$, 则:

$$\begin{aligned} \text{MSE}(\hat{\theta}_a) &= \text{Var}(\hat{\theta}_a) + (E\hat{\theta}_a - \theta)^2 \\ &= a^2 \text{Var}(\bar{x}) + (aE(\bar{x}) - \theta)^2 \\ &= \frac{a^2 \theta^2}{n} + \theta^2 (a - 1)^2. \end{aligned}$$

$\text{MSE}(\hat{\theta}_a)$ 关于 a 求导, 当 $a = \frac{n}{n+1}$ 时, $\text{MSE}(\hat{\theta}_a)$ 达到最小, 最小值为 $\frac{\theta^2}{n+1} < \text{MSE}(\bar{x})$.

第六题

题目

设 $x_1, x_2, \dots, x_n$ 是来自密度函数为

$$p(x; \theta) = e^{-(x-\theta)}, x \geq \theta$$

的总体的样本

(a) 求 θ 的最大似然估计 $\hat{\theta}_1$, 它是否是相合估计? 是否是无偏估计?

(b) 求 θ 的矩估计 $\hat{\theta}_2$, 它是否是相合估计? 是否是无偏估计?

答案

(a)

$$\begin{aligned}\hat{\theta}_1 &= \arg \max_{\hat{\theta}} \prod_{i=1}^n p(x_i; \hat{\theta}) \\ &= \arg \max_{\hat{\theta}} \exp(n\hat{\theta} - \sum_{i=1}^n x_i)\end{aligned}$$

观察可得当 $\forall i: x_i \geq \hat{\theta}$ 时, $\hat{\theta}$ 越大, $\arg \max_{\hat{\theta}}$ 里面的那个式子就越大. 故取 θ 为 $\min\{x_i: i \in \{1, 2, \dots, n\}\}$

若各个 $x_i: i \in \{1, 2, \dots, n\}$ 来自密度函数为 $p(x; \theta)$ 真实分布:

相合性:

$$\forall \varepsilon > 0: \forall \delta > 0: n \rightarrow \infty:$$

$$P(\min\{x_i: i \in \{1, 2, \dots, n\}\} > \theta + \varepsilon) = \prod_{i=1}^n P(x_i > \theta + \varepsilon) = e^{-\varepsilon n} < \delta$$

是 (依概率) 相合的.

无偏性: $E(\theta_1) > \theta$, 所以 θ_1 不是无偏的.

(b)

$$\begin{aligned}E(x_i) &= \int_{\theta}^{\infty} x \exp(\theta - x) dx & x' \leftarrow x - \theta \\ &= \int_0^{\infty} (x' + \theta) \exp(-x') dx' \\ &= \theta + 1\end{aligned}$$

令 $\bar{x} = \frac{1}{n} \sum_{i=1}^n x_i$, 矩估计为 $\theta_2 = \bar{x} - 1$.

若各个 $x_i: i \in \{1, 2, \dots, n\}$ 来自密度函数为 $p(x; \theta)$ 真实分布:

无偏性: 矩估计一定是无偏的. 若不使用这个性质, 则验算: $E(\theta_2) = E(\bar{x}) - 1 = \theta$

相合性: 矩估计一定是 (矩) 相合的. 若不使用这个性质, 则验算: $\lim_{n \rightarrow \infty} \text{Var}(\bar{x} - 1) = \text{Var}(\bar{x}) = 0$ 故 θ_2 二阶收敛到 θ

第 16 周习题

贝叶斯估计部分

第一题

问题

设一页书上的错别字个数服从泊松分布 $P(\lambda)$, λ 有两个可能取值: 1.5 和 1.8, 且先验分布为

$$P(\lambda = 1.5) = 0.45, \quad P(\lambda = 1.8) = 0.55$$

现检查了一页, 发现有 3 个错别字, 试求 λ 的后验分布。

解答

由题意可得,

$$P(X = 3|\lambda = 1.5) = \frac{1.5^3}{3!}e^{-1.5}.$$

$$P(X = 3|\lambda = 1.8) = \frac{1.8^3}{3!}e^{-1.8}.$$

$$\begin{aligned} P(X = 3) &= P(X = 3|\lambda = 1.8)P(\lambda = 1.8) \\ &\quad + P(X = 3|\lambda = 1.5)P(\lambda = 1.5) \\ &= \frac{1.51875e^{-1.5} + 3.207e^{-1.8}}{6}. \end{aligned}$$

接下来计算 λ 的后验分布,

$$\begin{aligned} P(\lambda = 1.5|X = 3) &= \frac{P(X = 3|\lambda = 1.5)P(\lambda = 1.5)}{P(X = 3)} \\ &= 0.3899. \end{aligned}$$

$$\begin{aligned} P(\lambda = 1.8|X = 3) &= 1 - P(\lambda = 1.5|X = 3) \\ &= 0.6101. \end{aligned}$$

第二题

问题

验证: 正态分布方差 (均值已知) 的共轭先验分布是倒伽玛分布。(提示: 若 X 服从伽玛分布, 那么称随机变量 $1/X$ 的分布为倒伽玛分布。)

解答

设总体 $X|\sigma^2 \sim N(\mu_0, \sigma^2)$, 其中 μ_0 已知, $x_1, x_2, \dots, x_n$ 为样本, 令 σ^2 的先验分布为倒伽马分布 $IGa(\alpha, \lambda)$, 其密度函数为

$$\pi(\sigma^2) = \frac{\lambda^\alpha}{\Gamma(\alpha)} \left(\frac{1}{\sigma^2}\right)^{\alpha+1} e^{-\frac{\lambda}{\sigma^2}}, \sigma^2 > 0.$$

则 σ^2 的后验分布为,

$$\begin{aligned} & \pi(\sigma^2|x_1, x_2, \dots, x_n) \\ &= \frac{p(x_1, x_2, \dots, x_n|\sigma^2)\pi(\sigma^2)}{\int p(x_1, x_2, \dots, x_n|\sigma^2)\pi(\sigma^2)d\sigma^2} \\ &= \frac{(2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_0)^2\right\} \frac{\lambda^\alpha}{\Gamma(\alpha)} \left(\frac{1}{\sigma^2}\right)^{\alpha+1} e^{-\frac{\lambda}{\sigma^2}}}{\int_0^{+\infty} (2\pi\sigma^2)^{-\frac{n}{2}} \exp\left\{-\frac{1}{2\sigma^2} \sum_{i=1}^n (x_i - \mu_0)^2\right\} \frac{\lambda^\alpha}{\Gamma(\alpha)} \left(\frac{1}{\sigma^2}\right)^{\alpha+1} e^{-\frac{\lambda}{\sigma^2}} d\sigma^2} \\ &= \frac{\left(\frac{1}{\sigma^2}\right)^{\alpha+\frac{n}{2}+1} \exp\left\{-\frac{1}{\sigma^2} \left[\lambda + \frac{1}{2} \sum_{i=1}^n (x_i - \mu_0)^2\right]\right\}}{\int_0^{+\infty} \left(\frac{1}{\sigma^2}\right)^{\alpha+\frac{n}{2}+1} \exp\left\{-\frac{1}{\sigma^2} \left[\lambda + \frac{1}{2} \sum_{i=1}^n (x_i - \mu_0)^2\right]\right\} d\sigma^2} \\ &= \frac{\left[\lambda + \frac{1}{2} \sum_{i=1}^n (x_i - \mu_0)^2\right]^{\alpha+\frac{n}{2}}}{\Gamma(\alpha + \frac{n}{2})} \left(\frac{1}{\sigma^2}\right)^{\alpha+\frac{n}{2}+1} \exp\left\{-\frac{1}{\sigma^2} \left[\lambda + \frac{1}{2} \sum_{i=1}^n (x_i - \mu_0)^2\right]\right\}. \end{aligned}$$

可以看出, $\sigma^2|x_1, x_2, \dots, x_n \sim IGa(\alpha + \frac{n}{2}, \lambda + \frac{1}{2} \sum_{i=1}^n (x_i - \mu_0)^2)$, 即证明成立。

■

第三题

问题

设 $x_1, x_2, \dots, x_n$ 为来自如下幂级数分布的样本, 总体分布密度为

$$p(x; c, \theta) = cx^{c-1}\theta^{-c}I_{\{0 \leq x \leq \theta\}}, c > 0, \theta > 0.$$

试证:

1. 若 c 已知, 则 θ 的共轭先验分布为帕雷托分布;
2. 若 θ 已知, 则 c 的共轭先验分布为伽玛分布。

解答

(a) 设 $\pi(\theta) = \alpha\mu^\alpha\theta^{-(\alpha+1)}I\{\theta \geq \mu\}$ $\alpha \geq 1, \mu > 0$. 则 θ 的后验分布密度函数为

$$\begin{aligned}\pi(\theta|x) &= \frac{p(x|\theta)\pi(\theta)}{\int_0^{+\infty} p(x|\theta)\pi(\theta)d\theta} \\&= \frac{c^n (\prod_{i=1}^n x_i)^{c-1} \theta^{-nc} I\{\theta \geq x_{(n)}\} \cdot \alpha\mu^\alpha\theta^{-(1+\alpha)} I\{\theta \geq \mu\}}{\int_0^{+\infty} c^n (\prod_{i=1}^n x_i)^{c-1} \theta^{-nc} I\{\theta \geq x_{(n)}\} \cdot \alpha\mu^\alpha\theta^{-(1+\alpha)} I\{\theta \geq \mu\} d\theta} \\&= \frac{\theta^{-nc} \cdot \theta^{-(1+\alpha)} I\{\theta \geq \theta_0\}}{\int_{\theta_0}^{+\infty} \theta^{-nc} \cdot \theta^{-(1+\alpha)} d\theta} = (nc + \alpha)\theta_0^{nc+\alpha}\theta^{-(nc+\alpha+1)} I\{\theta \geq \theta_0\}\end{aligned}$$

其中 $\theta_0 = \max\{x_{(n)}, \mu\}$, 因此

$$\pi(\theta|x) \sim PA(nc + \alpha, \theta_0)$$

所以当 c 已知时帕雷托分布为 θ 的共轭先验分布.

(b) 设 $\pi(c) = \frac{\lambda^\alpha}{\Gamma(\alpha)} e^{-\lambda c} \cdot c^{\alpha-1} I\{c > 0\}$ $\alpha > 0, \mu > 0$. 则 c 的后验密度函数为

$$\begin{aligned}\pi(c|x) &= \frac{p(x|c)\pi(c)}{\int_0^\infty p(x|c)\pi(c)dc} \\&= \frac{c^n (\prod_{i=1}^n x_i)^{c-1} \theta^{-nc} \cdot e^{-\lambda c} c^{\alpha-1}}{\int_0^\infty c^n (\prod_{i=1}^n x_i)^{c-1} \theta^{-nc} \cdot e^{-\lambda c} c^{\alpha-1} dc} \\&= \frac{(\lambda - \sum_{i=1}^n (\ln x_i - \ln \theta))^{n+\alpha}}{\Gamma(n+\alpha)} c^{n+\alpha-1} \exp\left\{-c\left[\lambda - \sum_{i=1}^n (\ln x_i - \ln \theta)\right]\right\}\end{aligned}$$

这说明 $c|x \sim Ga(n+\alpha, \lambda - \sum_{i=1}^n (\ln x_i - \ln \theta))$.

第四题

问题

设 $x_1, x_2, \dots, x_n$ 是来自参数为 λ 的泊松分布 $P(\lambda)$ 的样本. 假定 λ 的先验分布为伽玛分布 $Ga(\alpha, \beta)$.

1. 计算 λ 的后验分布。
2. 求 λ 的贝叶斯估计 $\hat{\lambda}_1$ 。
3. 求 λ 的极大似然估计 $\hat{\lambda}_2$ 。

解答

(1)

$$\begin{aligned}P(x|\lambda) &= \frac{\lambda^x}{x!} e^{-\lambda} \\ \pi(\lambda) &= \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta\lambda} \\ h(x_1, x_2, \dots, x_n, \lambda) &= \prod_{i=1}^n \frac{\lambda^{x_i}}{(x_i)!} e^{-\lambda} \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta\lambda} \\ m(x_1, x_2, \dots, x_n) &= \int_0^{+\infty} h(x_1, x_2, \dots, x_n, \lambda) d\lambda \\ \pi(\lambda|x_1, x_2, \dots, x_n) &= \frac{h(x_1, x_2, \dots, x_n, \lambda)}{m(x_1, x_2, \dots, x_n)} \\ &= \frac{\prod_{i=1}^n \frac{\lambda^{x_i}}{(x_i)!} e^{-\lambda} \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta\lambda}}{\int_0^{+\infty} \prod_{i=1}^n \frac{\lambda^{x_i}}{(x_i)!} e^{-\lambda} \cdot \frac{\beta^\alpha}{\Gamma(\alpha)} \lambda^{\alpha-1} e^{-\beta\lambda} d\lambda} \\ &= \frac{(n+\beta)(\sum_{i=1}^n x_i + \alpha)}{\Gamma(\sum_{i=1}^n x_i + \alpha)} \lambda^{\sum_{i=1}^n x_i + \alpha - 1} e^{-(n+\beta)\lambda}\end{aligned}$$

可得, $\lambda|x_1, x_2, \dots, x_n \sim Ga(\sum_{i=1}^n x_i + \alpha, n + \beta)$.

(2) 使用后验分布的均值作为参数的贝叶斯估计:

$$\begin{aligned}\lambda|X &\sim Ga(\sum_{i=1}^n x_i + \alpha, n + \beta). \\ \hat{\lambda}_1 &= \frac{\sum_{i=1}^n x_i + \alpha}{n + \beta}.\end{aligned}$$

(3) 参数的 MLE:

$$\begin{aligned}L(\lambda) &= P(x_1, x_2, \dots, x_n|\lambda) \\ &= \prod_{i=1}^n \frac{\lambda^{x_i}}{(x_i)!} e^{-\lambda}. \\ \ln L(\lambda) &= \sum_{i=1}^n x_i \ln \lambda - \lambda n - \sum_{i=1}^n \ln(x_i!).\end{aligned}$$

$\ln L(\lambda)$ 关于 λ 求导, 并令其等于 0, 解得 $\hat{\lambda}_2 = \bar{x}$.

第五题

问题

设随机变量 X 服从负二项分布，其概率分布为

$$f(x|p) = \binom{x-1}{k-1} p^k (1-p)^{x-k}, x = k, k+1, \dots$$

证明其成功概率 p 的共轭先验分布族为贝塔分布族。

答案

令成功概率 p 的先验分布为 $Be(a, b)$, $a > 0$, $b > 0$, 则 $x_1, x_2, \dots, x_n$ 与 θ 的联合分布为:

$$\begin{aligned} h(x_1, x_2, \dots, x_n, p) &= \prod_{i=1}^n \binom{x_i-1}{k-1} p^{nk} (1-p)^{\sum_{i=1}^n x_i - nk} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} p^{a-1} (1-p)^{b-1}. \\ m(x_1, x_2, \dots, x_n) &= \int_0^1 h(x_1, x_2, \dots, x_n, p) dp \\ &= \prod_{i=1}^n \binom{x_i-1}{k-1} \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} \frac{\Gamma(nk+a)\Gamma(\sum_{i=1}^n x_i - nk + b)}{\Gamma(\sum_{i=1}^n x_i + a + b)}. \\ \pi(p|x_1, x_2, \dots, x_n) &= \frac{h(x_1, x_2, \dots, x_n, p)}{m(x_1, x_2, \dots, x_n)} \\ &= \frac{\Gamma(\sum_{i=1}^n x_i + a + b)}{\Gamma(nk+a)\Gamma(\sum_{i=1}^n x_i - nk + b)} p^{nk+a-1} (1-p)^{\sum_{i=1}^n x_i - nk + b - 1}. \end{aligned}$$

即成功概率 p 的后验分布为 $Be(nk+a, \sum_{i=1}^n x_i - nk + b)$, 证明成立。

假设检验基本概念部分

第六题

问题

设 $x_1, x_2, \dots, x_n$ 是来自 $N(\mu, 1)$ 的样本，考虑如下假设检验问题

$$H_0: \mu = 2 \quad \text{vs} \quad H_1: \mu = 3$$

若检验由拒绝域为 $W = \{\bar{x} \geq 2.6\}$ 确定。

1. 当 $n = 20$ 时求检验犯两类错误的概率;

2. 如果要使得检验犯第二类错误的概率 $\beta \leq 0.01$, n 最小应取多少?

3. 证明: 当 $n \rightarrow \infty$ 时, $\alpha \rightarrow 0$, $\beta \rightarrow 0$ 。

答案

(1) 在 H_0 成立时, $\bar{x} \sim N(2, 1/20)$, 犯第一类错误的概率为:

$$\alpha = P(\bar{x} \geq 2.6 | H_0) = P\left(\frac{\bar{x} - 2}{\sqrt{1/20}} \geq \frac{2.6 - 2}{\sqrt{1/20}}\right) = 0.0037.$$

同理, 在 H_1 成立时, $\bar{x} \sim N(3, 1/20)$, 犯第二类错误的概率为:

$$\beta = P(\bar{x} < 2.6 | H_1) = P\left(\frac{\bar{x} - 3}{\sqrt{1/20}} < \frac{2.6 - 3}{\sqrt{1/20}}\right) = 0.0367.$$

(2) 可得:

$$\beta = P(\bar{x} < 2.6 | H_1) = P\left(\frac{\bar{x} - 3}{\sqrt{1/n}} < \frac{2.6 - 3}{\sqrt{1/n}}\right) \leq 0.01.$$
$$n \geq 33.93.$$

因而, n 最小应取 34 才使得检验犯第二类错误的概率 $\beta \leq 0.01$.

(3) 证明:

当样本量为 n 时,

$$\alpha = P(\bar{x} \geq 2.6 | H_0) = P\left(\frac{\bar{x} - 2}{\sqrt{1/n}} \geq \frac{2.6 - 2}{\sqrt{1/n}}\right) = 1 - \Phi(0.6\sqrt{n}).$$

$$\beta = P(\bar{x} < 2.6 | H_1) = P\left(\frac{\bar{x} - 3}{\sqrt{1/n}} < \frac{2.6 - 3}{\sqrt{1/n}}\right) = 1 - \Phi(0.4\sqrt{n}).$$

当 $n \rightarrow \infty$, $\Phi(0.6\sqrt{n}) \rightarrow 1$, $\Phi(0.4\sqrt{n}) \rightarrow 1$, 使得 $\alpha \rightarrow 0$, $\beta \rightarrow 0$. ■

第七题

问题

设 $x_1, x_2, \dots, x_{20}$ 是来自 $0-1$ 总体 $b(1, p)$ 的样本, 考虑如下检验问题:

$$H_0: p = 0.2 \quad \text{vs} \quad H_1: p \neq 0.2$$

取拒绝域为 $W = \{\sum_{i=1}^{20} x_i \geq 7 \text{ 或 } \sum_{i=1}^{20} x_i \leq 1\}$,

1. 求 $p = 0, 0.1, 0.2, \dots, 0.9, 1$ 时的势并由此画出势函数的图;


2. 求在 $p = 0.05$ 时犯第二类错误的概率。

答案

(1) 势函数的计算公式为:

$$\begin{aligned} g(p) &= P_p\left(\sum_{i=1}^{20} x_i \geq 7 \text{ or } \sum_{i=1}^{20} x_i \leq 1\right) \\ &= \sum_{i=0}^1 \binom{20}{i} p^i (1-p)^{20-i} + \sum_{i=7}^{20} \binom{20}{i} p^i (1-p)^{20-i}. \end{aligned}$$

当 $p = 0, 0.1, 0.2, \dots, 0.9, 1$ 时, $g(p) = 1.00, 0.39, 0.16, 0.40, 0.75, 0.94, 0.99, 1.00, 1.00, 1.00, 1.00$.
图像如下:



(2) 当 $p = 0.05$ 时, $\beta = 1 - g(0.05) = 0.2641$.

正态总体假设检验部分

答题要求

本节下的问题都是应用题 (1) 在应用题中, 需要写出严格地写出拒绝域并计算 p 值; (2) 无特殊指定, 显著性检验 $\alpha = 0.05$;

第八题

问题

化肥厂用自动包装机包装化肥，每包的质量服从正态分布，其平均质量为 100kg，标准差为 1.2kg。某日开工后，为了确定这天包装机工作是否正常，随机抽取 9 袋化肥，称得质量（单位:kg）如下：

99.3 98.7 100.5 101.2 98.3 99.7 99.5 102.1 100.5

设方差稳定不变，问这一天包装机的工作是否正常（取 $\alpha = 0.05$ ）？

答案

此题为总体方差已知时关于正态总体均值的双边假设检验问题，总体 $X \sim N(\mu, 1.2^2)$ 。

$$H_0: \mu = 100 \quad vs \quad H_1: \mu \neq 100.$$

拒绝域： $W = \{|u| \geq u_{1-\alpha/2} = 1.96\}$ 。

$$\text{计算得：}\bar{x} = 99.98, u = \frac{3(99.98-100)}{1.2} = -0.05, p = 0.96 > \alpha.$$

由于 u 值未落在拒绝域内，没有充分理由拒绝原假设，所以接受原假设，认为这天包装机工作正常。

第九题

问题

考察一鱼塘中的鱼的含汞量，随机地选取 10 条鱼，测得各条鱼的含汞量（单位：mg）为

0.8 1.6 0.9 0.8 1.2 0.4 0.7 1.0 1.2 1.1

设鱼的含汞量服从正态分布 $N(\mu, \sigma^2)$ 。试检验假设 $H_0: \mu \leq 1.2$ vs $H_1: \mu > 1.2$ （取 $\alpha = 0.1$ ）。

答案

此题为总体方差未知时关于正态总体均值的单边假设检验问题。 $n=10$ 。

$$H_0: \mu \leq 1.2 \quad vs \quad H_1: \mu > 1.2.$$

拒绝域： $W = \{t > t_{1-\alpha}(n-1) = t_{0.9}(9) = 1.3830\}$ 。

$$\text{计算得：} t = -2.2027 < 1.3820, p = 0.97 > \alpha.$$

在显著效水平为 0.1 下，由于 t 值未落在拒绝域内，没有充分理由拒绝原假设，所以接受原假设。

第十题

问题

一药厂生产一种新的止痛片，厂方希望验证服用新药片后至开始起作用的时间间隔较原有止痛片至少缩短一半，因此厂方提出需检验假设

$$H_0 : \mu_1 = 2\mu_2 \quad \text{vs} \quad H_1 : \mu_1 > 2\mu_2$$

此处， μ_1, μ_2 分别是服用原有止痛片和服用新止痛片后至开始起作用的时间间隔的总体的均值。设两总体均为正态分布且方差分别为已知值 σ_1^2, σ_2^2 ，现分别在两总体中取一样本 $x_1, \dots, x_n$ 和 $y_1, \dots, y_m$ ，设两个样本独立。试给出上述假设检验问题的检验统计量，拒绝域，并给出 p 值的计算公式。

答案

设 X 为服用原止痛片至开始起作用的时间间隔， $x_1, x_2, \dots, x_n$ 为样本， Y 为服用新止痛片至开始起作用的时间间隔， $y_1, y_2, \dots, y_m$ 为样本，且两样本独立， $X \sim N(\mu_1, \sigma_1^2)$ ， $Y \sim N(\mu_2, \sigma_2^2)$ 。

此题为两样本总体方差已知时关于正态总体均值的单边假设检验问题。

$$H_0 : \mu_1 = 2\mu_2 \quad \text{vs} \quad H_1 : \mu_1 > 2\mu_2.$$

$$\text{拒绝域: } W = \{u > u_{1-\alpha}\}.$$

$$\text{检验统计量为: } u = \frac{\bar{x} - 2\bar{y}}{\sqrt{\frac{\sigma_1^2}{m} + \frac{4\sigma_2^2}{n}}} \sim N(0, 1).$$

$$\text{令 } u_0 = \frac{\bar{x} - 2\bar{y}}{\sqrt{\frac{\sigma_1^2}{m} + \frac{4\sigma_2^2}{n}}}, \text{ 其中 } \bar{x} \text{ 和 } \bar{y} \text{ 由样本计算得到。}$$

$$p \text{ 值的计算公式为: } p = P(u > u_0).$$

第十一题

问题

对冷却到 -0.72°C 的样品用 A, B 两种测量方法测量其融化到 0°C 时的潜热, 数据如下:

方法 A:	79.98	80.04	80.02	80.04	80.03	80.03	80.04	79.97
	80.05	80.03	80.02	80.00	80.02			
方法 B:	80.02	79.94	79.98	79.97	80.03	79.95	79.97	79.97

假设它们服从正态分布, 方差相等。在显著性水平 $\alpha = 0.05$ 时, 检验两种测量方法的平均性能是否相等?

答案

设 X 和 Y 为两种测量方法, $X \sim N(\mu_1, \sigma^2)$, $Y \sim N(\mu_2, \sigma^2)$.

此题为两样本总体方差未知且相等时关于正态总体均值的双边假设检验问题。
 $n=13$, $n=8$.

$H_0: \mu_1 = \mu_2$ vs $H_1: \mu_1 \neq \mu_2$.

拒绝域: $W = \{|t| > t_{1-\alpha/2}(n+m-2) = 2.093\}$.

检验统计量为: $t = \frac{\bar{x} - \bar{y}}{s_w \sqrt{\frac{1}{m} + \frac{1}{n}}} = 3.31 > 2.093$, $p = 0.0036 < \alpha$.

由于 t 值落在拒绝域内, 有充分理由拒绝原假设, 所以认为两种测量方法的平均性能有显著差异。

第十二题

问题

为了比较测定活水中氯气含量的两种方法, 特在各种场合收集到 8 个污水水样, 每个水样均用这两种方法测定氯气含量 (单位: mg/l), 具体数据如下:

设总体为正态分布。试比较两种测定方法是否有显著差异。

答案

可看作成对数据的双边假设检验问题。令其差 $d_i = s_i - y_i$.

$H_0: d = 0$ vs $H_1: d \neq 0$.

拒绝域: $W = \{|t| \geq t_{1-\alpha/2}(n+m-1) = 2.3646\}$.

检验统计量为: $t = \frac{\bar{d}}{s_d/\sqrt{n}} = 3.646 > 2.3646$, $p = 0.0082 < \alpha$.

水样号	方法一 (x)	方法二 (y)	差 ($d = x - y$)
1	0.36	0.39	-0.03
2	1.35	0.84	0.51
3	2.56	1.76	0.80
4	3.92	3.35	0.57
5	5.35	4.69	0.66
6	8.33	7.70	0.63
7	10.70	10.52	0.18
8	10.91	10.92	-0.01

由于 t 值落在拒绝域内，所以有利于拒绝原假设，认为两种测定方法有显著差异。